

캡스톤디자인2 설계최종보고서

생성형 AI를 이용한 시상면 X-Ray 영상에서의 척추 매개변수 자동 분석

- 과목명: 캡스톤디자인2
- 과목 담당교수: 김인중
- 연계 기업명: 에스포항병원
- 제출일: 2024년 12월 일
- 프로젝트 팀원명단:

이름	학번	제1전공 (심화전공)	제2전공	담당 업무 팀장부터 기입
			-	
		.	-	

- 캡스톤 설계 완성도 [지도교수가 채점]

점수	캡스톤 작품 구현 완성도	
	설명	지도교수 평가 해당란에 체크(O)
5	상용 제품으로도 손색이 없는 수준	
4	모든 기능이 잘 작동하고 최적화도 어느 정도 됨	
3	전반적인 기능이 원활히 작동함. 성능은 기존 제품이나 논문에 비해 미흡한 편	
2	일부 기능만 구현하거나 동작 중 오류가 가끔 발생	
1	다수 기능이 미구현되었거나 또는 미작동함	

날짜:

지도교수명:

김인중 (서명)

설계 결과 요약서						
설계주제 (Title)	생성형 AI를 이용한 시상면 X-Ray 영상에서의 척추 매개변수 자동 분석					
주제어 (Keywords)	생성형 AI, X-Ray, 척추골반지표, AI					
설계팀원 명단 (Designers)						
지도교수, 산업체 자문위원 (Advisor)	김인중, 박상진					
설계 기간 (Period)	2024년 1월 1일 ~ 2024년 12월 31일 (총 12개월)					
설계문제의 정의 (Problem Statement)	Spinopelvic Parameter(척추골반지표)는 환자의 측면 척추 X-ray 이미지에서 측정할 수 있으며, 척추 퇴행성 질환을 진단 및 평가하는 데 사용된다. 기존에는 의사가 직접 계산하였지만, 이는 시간이 많이 소요되고 측정자에 따라 오차가 발생할 수 있다. 따라서 딥러닝 모델을 통해 이 작업을 자동화하여 비용을 절감하고 일관성을 높인다.					
설계요소(Design Elements) (해당요소에 O표)	목표설정	분석 및 개념설계	상세설계	구현 및 제작	시험 및 평가	기타
	O	O	O	O	O	
제한조건 (Constraints) (해당요소에 O표)	제작비용 및 기간	실행 및 개발환경	사회 및 윤리	안정성/신뢰성 및 미학	산업표준	기타
	O	O	O	O		
설계결과물 (deliverables)	Spinopelvic Parameter Measurement, Spine Restoration Network, Hspine					
설계 결과의 요약 (Abstract) (100자 이내)	<p>Spinopelvic Parameter Measurement</p> <p>해당 프로젝트에서는 딥러닝 기술을 활용해 척추-골반 측정을 자동화하여 시간과 비용을 절감하고, 일관된 정확도를 보장하는 것을 목표로 하였다. 이에 분할 (segmentation), 측정 (measurement)로 구성된 딥러닝 모델을 활용하여 척추골반지표인 PT, SS, LL 각도를 자동으로 계산하였다.</p> <p>Spine Restoration Network</p> <p>딥러닝 모델은 척추 보조기구 (screw)가 포함된 의료 영상에서 척추 보조기구로 인해 척추 뼈를 정확히 식별하기 어렵다. 이를 해결하기 위해 생성형 AI인 VQGAN 모델을 사용한 Spine Restoration Network를 개발하였다.</p> <p>Hspine (Graphical User Interface)</p> <p>프로그래밍 지식 없이도 Spinopelvic Parameter Measurement 기술을 쉽게 사용할 수 있도록 설계되어, 임상 환경에서 활용 가능하다.</p>					

Summary

Date:

Course Name	Capstone Design 2	Year/Semester	2024/2
Design Title	Automatic Analysis of Spinal Parameters in Sagittal X-Ray Images Using Generative AI		
Keywords	Generative AI, X-ray, Spinopelvic Parameter, AI		
Designers (Students)			
Advisor(s)	Injung Kim, Sangjin Park		
Design Problem Definition	Spinopelvic parameters can be measured from a patient's lateral spinal X-ray images and are used for diagnosing and evaluating degenerative spinal diseases. Traditionally, these measurements were performed manually by physicians, which is time-consuming and prone to errors depending on the observer. Therefore, automating this process using deep learning models can reduce costs and improve consistency.		
Design Constraints	Production Cost and Duration, Execution and Development Environment, Social and Ethical Considerations, Stability/Reliability and Aesthetics		
Design Objectives	Bone mask segmentation from lateral spinal X-ray images of patients, Extraction of spinopelvic parameters, Development of a robust model for images with spinal implants, Development of a GUI for deploying the AI model in clinical settings		
Deliverables	Spinopelvic Parameter Measurement, Spine Restoration Network, Hspine		
Extended Abstracts	<p>Spinopelvic Parameter Measurement</p> <p>This project aims to automate spinopelvic parameter measurements using deep learning technology to save time and costs while ensuring consistent accuracy. A deep learning model comprising segmentation and measurement was employed to automatically calculate spinopelvic parameters such as PT, SS, and LL angles.</p> <p>Spine Restoration Network</p> <p>In medical images containing spinal implants (e.g., screws), it can be challenging to accurately identify the spinal bones due to the presence of these implants. To address this issue, the Spine Restoration Network was developed using the generative AI model, VQGAN.</p> <p>Hspine (Graphical User Interface)</p> <p>Designed for ease of use without requiring programming knowledge, the Hspine GUI enables the application of Spinopelvic Parameter Measurement technology in clinical environments.</p>		

● Level Descriptor (문제수준 설명)

문제속성	문제수준 설명	만족 여부
1. 지식의 깊이	최신 정보와 관련 연구결과를 활용하고 있다.	○
2. 상충되는 요건의 범위	상충될 수 있는 기술적, 공학적 또는 컴퓨팅적 이슈를 다루고 있다.	○
3. 분석의 깊이	해답이 명확하지 않은 문제를 해결하기 위해 깊이 있는 사고와 분석 과정을 다루고 있다.	○
4. 생소한 주제	자주 접하지 않는 공학문제 또는 컴퓨팅문제를 다루고 있다.	○
5. 문제의 범위	전공 분야의 일반적인 실무 영역을 벗어난 범위를 다루고 있다.	○
6. 이해당사자의 요구수준 및 범위	다양한 이해 당사자들의 요구사항들을 고려하고 있다.	○
7. 상호의존성	상호 의존적인 여러 세부 문제들이 결합된 종합적인 문제로 구성되어 있다.	○
8. 다양한 영향 고려	다양한 분야에 미치는 영향을 고려하고 있다.	○

0. Executive SUMMARY

추진배경:

Spinopelvic Parameter(척추골반지표)는 환자의 측면 척추 X-ray 이미지에서 측정할 수 있으며, 척추 퇴행성 질환을 진단 및 평가하는 데 사용된다. 기존에는 의사가 직접 계산하였지만, 이는 시간이 많이 소요되고 측정자에 따라 오차가 발생할 수 있다. 따라서 딥러닝 모델을 통해 이 작업을 자동화하여 비용을 절감하고 일관성을 높인다.

목표 및 내용:

목표

- 환자의 측면 척추 X-ray 이미지에서 뼈 mask segmentation
- Spinopelvic Parameter 추출
- 척추 보조기구가 삽입된 이미지에서도 강건한 모델 개발
- AI 모델을 현장에서 사용할 수 있는 GUI 개발

내용

- 척추매개변수 측정 자동화를 위한 의료 데이터 수집 및 라벨링
- X-ray 영상에서 segmentation map을 추출하는 AI 기술 개발
- segmentation을 기반으로 척추 매개변수를 측정하는 computer vision 알고리즘 개발
- 척추 보조기구를 제거하는 생성적 AI 기반 전처리 네트워크 개발
- 의료 현장에서 연구된 내용을 적용할 수 있는 Gradio 기반의 GUI 개발

기대효과:

2022년 KISTI가 발표한 ASTI market insight AI 의료 및 헬스 케어에 따르면 AI 의료/헬스케어의 세계 시장규모는 2021년 69억 달러에서 연 평균 46.2 %로 급성장해 2027년 674억 달러의 규모를 형성할 것으로 전망되고 있다. 실용성 측면에서 의료 X-ray 영상을 빠른 시간내에 일관적으로 분석 가능하다는 점을 미루어 보아, 의료 진단의 효율성을 증가시키고 불확실성을 줄일 수 있다. 지속가능한 수익모델로 루닛의 암 진단 관련 영상 판독을 보조하는 서비스가 있다. 글로벌 의료영상 장비 기업인 GE헬스케어, 필립스, 후지필름 등을 통해 각 지역에 루닛 인사이트 등 소프트웨어를 판매하는 형태로 지속가능한 수익모델을 구성하였다.

세부내용:

Spinopelvic Parameter 추출

해당 프로젝트에서는 딥러닝 기술을 활용해 척추-골반 측정을 자동화하여 시간과 비용을 절감하고, 일관된 정확도를 보장하는 것을 목표로 하였다. 연구는 분할(segmentation)과 측정(measurement)의 두 단계로 구성되었다. 분할 단계에서는 TransUnet 모델을 사용해 척추뼈를 식별했다. 측정 단계에서는 분할 결과를 바탕으로 PT, SS, LL 각도를 계산하는 알고리즘을 개발해, 자동으로 척추골반지표를 측정했다.

Spine Restoration Network 개발

딥러닝 모델은 척추 보조기구 (screw)로 인해 의료 영상에서 척추 뼈를 정확히 식별하기 어렵다. 이를 해결하기 위해 VQGAN 모델을 사용한 Spine Restoration Network를 개발하여, 1,532개의 screw가 없는 정상 이미지를 학습해 보조기구를 제거한 이미지를 생성했다. 그러나 환자 간 차이로 인해 복원 이미지와 원본 간 불일치가 발생할 수 있었다. 이를 보완하기 위해, 원본 이미지와 복원 이미지의 차이를 감마 보정 후 계산하고, 이를 바탕으로 screw 영역을 제거한 뒤 Inpainting 기법으로 복원했다.

Hspine (Graphical User Interface) 제작

이 인터페이스를 통해 의료 전문가들은 X-ray 이미지를 업로드하고, 자동으로 척추-골반 매개변수를 추출하며, 분할 마스크와 주요 지점을 시각화할 수 있다. 또한, 필요에 따라 측정값을 조정할 수 있으며, 결과를 CSV 파일로 내보내었다.

수행결과:

Spinopelvic Parameter 추출

test (150장)에 대한 측정 결과, PT의 평균 절대 오차는 1.377도, SS는 3.272도, LL은 4.421도로 나타났으며, 모든 각도는 허용 가능한 표준 편차 범위 내에 있었다.

Spine Restoration Network 개발

183개의 screw 포함 데이터셋을 테스트한 결과, Spine Restoration Network를 사용했을 때 segmentation 성능이 10.39% 향상되었다.

Hspine (Graphical User Interface) 제작

프로그래밍 지식 없이도 쉽게 사용할 수 있도록 설계되어, 임상 환경에서 활용 가능하다.

결과물:

2024 공학페스티벌 - 특별상

국립한밭대학교 창의적 종합설계 경진대회 – 은상

Hspine (Graphical User Interface) 제작

논문 작성 예정

1. PROJECT OVERVIEW

1.1. Introduction

I. 필요성 및 문제정의

A. 과제의 필요성

퇴행성 척추 질환의 진단과 평가에 사용되는 척추골반지표의 수동 측정은 시간 소모가 크고 의료진에 따라 일관성이 떨어짐. 이에 따라 척추 X-ray 영상에서 척추골반지표를 자동으로 측정하는 AI가 필요.

B. 문제 정의

Problem Statement

- 척추 영상에서 척추골반지표를 측정하는 데 시간이 오래 걸리며, 의료진 간 측정 결과의 일관성이 부족.

Constraints


- 척추골반지표 측정을 위한 Pipeline 구축.
- 척추 보조기구가 포함된 영상에서도 정상적으로 척추골반지표 측정.

Objectives

- 척추골반지표 측정을 위한 Pipeline 구축. AI를 통해 척추 영상에서 Segmentation을 추출하고, Measurement Algorithm을 활용하여 척추골반지표 계산.
- 생성형 AI를 통해 보조기구가 포함된 척추 영상에서 보조기구를 제거하여 정확한 척추골반지표 측정.

Functions

- 보조기구 유무와 관계없이 영상에서 척추골반지표를 자동으로 측정.



1.2. Project Goal:

이 프로젝트는 환자의 측면 척추 X-ray 이미지에서 Spinopelvic Parameter를 자동으로 추출할 수 있는 AI 모델을 개발하는 것을 목표로 한다. 또한, 척추 보조기구가 삽입된 이미지에서도 강건한 모델을 만들고자 하고 위 내용을 바탕으로 임상 환경에서 쉽게 활용할 수 있는 사용자 친화적인 GUI를 제작하는 것이 최종 목표이다.

1.3. Key Project Stakeholders:

- 의료진 (Radiologists, Spine Surgeons): X-ray 영상을 분석하고 Spinopelvic Parameter를 평가하는데 직접적으로 활용한 의료 전문가.
- 환자: AI 기술을 통해 더 빠르고 정확한 진단 및 치료 계획의 수혜를 받는 대상.
- AI 연구자 및 개발자: 딥러닝 및 GUI 개발을 통해 프로젝트를 직접 구현하는 팀.
- 의료 기기 제조사 및 병원 관리자: AI 모델과 GUI를 실제 임상 환경에 도입하고 운영하는 책임을 지는 이해관계자.
- 윤리 및 규제 기관: 의료 AI 모델의 신뢰성과 안정성을 평가하고 임상에서의 사용을 승인하는 조직.

1.4. Project Requirements and Constraints:

1.4.1. Requirements

Functional Requirements

임상에 딥러닝 모델을 사용하게 될 때에는 환자의 X-ray 이미지 (딥러닝 모델의 input data) 가 어떤 형태를 띠고 있을지 알 수 없다. X-ray 촬영 시에 환자의 자세, 척추 보조기구가 X-ray 이미지에 포함되는 경우 등 다양한 이미지가 사용될 수 있다. 이런 상황을 극복하기 위해 딥러닝 모델은 다양한 이미지를 학습하여 어떤 형태의 환자 X-ray 이미지에 도 segmentation 과정 및 spinopelvic parameter를 계산할 수 있어야 한다.

일부 이미지들에 대해서는 위의 방법으로 극복되지 않는 경우도 있다고 판단된다. 따라서 Spine Restoration Network를 통해 척추보조기구가 제거된 이미지를 생성하여 정확한 계산을 할 수 있도록 한다. 더불어 병원에서 실제로 사용할 수 있도록 딥러닝 모델을 프로그래밍화 하여 제공하게 되는 경우, 오차가 발생하는 이미지에 대해서 수정 가능하도록 하여 실제로 환자의 질환을 진단하는 데 있어서 정확한 진단을 내릴 수 있도록 한다.

Spinopelvic parameter에 포함된 LL(Lumbar Lordosis) 외에도 lumbar 뼈를 임의로 선택하여 해당 뼈들 사이의 각도를 필요로 할 수 있다. 이 경우를 위해 LL 뿐만 아니라 모든 뼈들 사이의 각도를 구할 수 있도록 하고 이에 대한 검증도 필요로 한다.

Non-functional Requirements

환자의 진단에 사용되기 때문에 실시간으로 모델이 수 초 이내로 predict 해야 한다. 그렇기 때문에 딥러닝 모델의 구조를 너무 복잡하지 않게 조절해야 한다. 또한 학습 및 검증에 사용한 환자의 데이터는 개인정보가 포함된 데이터이다. 그렇기 때문에 진행 과정에 있어서 보안에 주의를 가지고 유출되는 일이 없도록 진행해야 한다.

해당 딥러닝 모델을 병원에서 사용하게 될 경우 컴퓨터 공학 관련 지식이 없는 전문 의료인의 경우 실제로 활용할 때 어려움을 느낄 수 있다. 따라서 직관적인 인터페이스와 사용하기 편리한 GUI를 제공해야 한다.

1.4.2. Constraints

제한조건	내용
제작비용 및 기간	프로젝트 계약기간이 끝나기 전까지 임상에서 사용 가능한 수준인 프로그램을 개발하고 공동논문을 작성해야 한다.
실행 및 개발환경	딥러닝 모델 특성상 모델의 변수들과 그 사이의 수 많은 연산량은 필연적이다. 본 프로젝트에서는 학습을 위해 8GB GTX 1080 그래픽 카드 8개와 24 GB TITAN RTX 2개를 사용하였지만 실제로 병원에서 사용하기 위해서는 CPU만 있다면 사용 가능하다.
사회 및 윤리	병원에서 사용하는 의료 데이터는 개인 식별 정보를 포함하고 있으므로 철저히 보호되어야 한다. 데이터 접근 및 사용 권한에 대한 통제를 필요로 하고, 모든 과정에 있어서 투명성을 유지해야 한다.
안정성 · 신뢰성 및 미학	임상에서 사용될 수 있을 정도 (신뢰성)의 척추골반지표 오차율을 보여야 한다. 이를 위해 의료진으로부터 프로그램이 개발되었을 때, 검증을 받아야 한다.
산업표준	해당 없음.
기타	해당 없음.

1.5. Deliverables (최종산출물):

1. Google Slide HSpine 사용설명서 및 데모영상
2. Spinopelvic Parameter Measurement, Spine Restoration Network, Hspine 소스파일
3. 논문

2. PROJECT BACKGROUND

2.1. Literature Review

<표. 최신 정보 및 선행연구 분석>

기 존 정 보 조 사 내 용	문헌명 및 저자	U-Net: Convolutional Networks for Biomedical image Segmentation - Olaf Ronneberger, Philipp Fischer, Thomas Brox
	문헌의 핵심내용	U-Net 구조 제안: 인코더는 컨볼루션 네트워크의 전형적인 아키텍처를 따른다. 디코더는 업샘플링(up-sampling) 및 컨볼루션을 통해 높은 해상도의 출력을 생성한다. 인코더의 고해상도 특징을 skip connection을 통해 디코더와 결합하여 정확한 출력을 만든다. 결론: U-Net 구조는 다양한 의료 이미지 Segmentation 에서 매우 좋은 성능을 발휘한다. Data augmentation 을 통해 이미지로도 학습이 가능하다.
	본 과제와의 공통점	본 프로젝트도 의료 이미지를 활용한 딥러닝 모델이기 때문에 데이터 수집에 어려움이 있다. 따라서 본 과제에서도 U-Net 구조를 사용하여 모델을 설계하였다.
	본 과제와의 차이점	U-Net은 단순히 CNN만을 사용한 모델이다. 본 과제에서는 후술할 ViT를 결합하여 전역적인 feature를 이해할 수 있도록 한다.
	문헌명 및 저자	An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale - Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, ...
	문헌의 핵심내용	Transformer 의 적용: NLP에서 널리 사용되고 이미 성능이 검증된 Transformer 를 컴퓨터 비전에 적용하여 ViT(Vision Transformer) 구조 개발 방법론: 이미지를 작은 패치로 나누고, 이 패치들을 단어 토큰으로 생각하고 각각의 패치에 대해 선형 임베딩을 생성하고 Transformer 모델에 사용한다. 성능: 대규모 데이터셋을 통해 사전학습시킨 Transformer를 Task에 맞게 fine-tuning 하여 사용한다. 이는 ResNet과 같은 기존의 CNN 모델들과 비교하여 훨씬 적은 자원으로도 우수한 결과를 낸다.

	결론: 순수한 Transformer 구조는 Image Segmentation 작업에서 CNN을 대체할 수 있다. 더 큰 데이터셋, 더 많은 자원을 사용하면 성능을 더 향상시킬 수 있다.
본 과제와의 공통점	본 프로젝트에서는 ViT 구조를 U-Net에 결합하여 사용한다. 이는 후술할 TransUNet의 모델 구조이다.
본 과제와의 차이점	순수한 Transformer 구조는 대규모 데이터셋을 통해 학습하는 것이 적합하다. 하지만 본 프로젝트에서는 소규모의 데이터셋을 수집하여 사용하기 때문에 CNN과 결합하여 사용하였다.
문헌명 및 저자	TransUNet: Transformers Make Strong Encoders for Medical Image Segmentation - Jieneng Chen, Yougyi Lu, Qihang Yu, Xiangde Luo, ...
문헌의 핵심내용	<p>TransUNet 제안: Transformer 와 U-Net을 결합한 하이브리드 아키텍처이다. Transformer 는 CNN feature 에서 토큰화된 이미지 패치를 입력으로 전역 문맥을 인코딩한다.</p> <p>방법론: CNN-Transformer 하이브리드 인코더: CNN을 먼저 사용하여 입력 이미지의 feature map을 생성하고, 이를 Transformer 인코더에 입력한다. Transformer 인코더: 이미지 패치를 1차원 시퀀스로 변환하여 Transformer에 입력한다.</p> <p>U-Net과의 결합: U-Net의 skip connection을 사용하여 다양한 해상도 수준에서 feature를 결합하여 세부적인 공간 정보를 보존한다.</p> <p>분석: skip connection을 추가할수록, 입력 해상도를 높일수록, 패치 크기를 줄일수록, 모델이 더 클수록 더 나은 성능을 얻을 수 있다.</p> <p>결론: TransUNet은 Transformer 와 U-Net의 장점을 결합하여 의료 영상 segmentation에서 뛰어난 성능을 발휘한다. 이 구조는 전역 문맥과 세부적인 공간 정보를 모두 잘 활용할 수 있다.</p>
본 과제와의 공통점	CNN과 ViT를 결합한 hybrid 모델을 사용한 TransUNet은 본 프로젝트의 base line 모델로서 사용되었다.
본 과제와의 차이점	TransUNet 은 3차원 영상을 입력으로 받지만 해당 구조를 2차원 입력에 맞게 수정하여 사용하였다. 또한 여러 기법들을 추가하여 성능을 보다 향상시킬 수 있었다.
문헌명 및 저자	PECI-Net: Bolus segmentation from video fluoroscopic swallowing study images using preprocessing ensemble and cascaded inference - Dougho Park, Younghun Kim, Harim Kang, Junmyoung Lee, ...

	<p>문헌의 핵심내용</p>	<p>배경: 비디오 투시 연하 검사 (VFSS) 영상을 이용한 자동 삼킴 장애 감지에서 bolus segmentation이 매우 중요하다. VFSS 영상은 반투명하고, 대비가 낮으며, 명확한 경계가 없어 이를 극복하고자 PECl-Net 구조를 제안</p> <p>PECl-Net 구조 제안: PEN과 CIN 구조를 제안한다. PEN (Preprocessing Ensemble Network)은 여러 전처리 알고리즘을 결합하여 VFSS 이미지의 선명도와 대비를 향상시킨다. CIN (Cascade Inference Network)은 다른 영역의 문맥을 활용하여 segmentation 과정에서의 모호성을 줄이고 신뢰할 수 없는 영역의 부작용을 방지한다.</p> <p>결과: 최근 개발된 네 가지 기준 모델보다 높은 성능을 보였다. TerausNet 보다 4.54%, UNet 보다 10.83% 더 높은 성능을 보여주었다. ablation study 를 통해 해당 구조들이 효과적임을 확인했다.</p> <p>결론: PECl-Net은 PEN과 CIN을 결합하여 높은 segmentation 정확도를 달성했다. 이 연구는 삼킴 장애 진단의 정확성과 일관성을 높이고 방사선 노출을 최소화 하는데 기여할 수 있는 자동화된 시스템의 가능성을 제시한다.</p>
	<p>본 과제와의 공통점</p>	<p>질환 진단의 자동화 및 일관된 결과를 얻을 수 있는 딥러닝 모델을 사용했다는 점에서 다른 선행 연구들보다 가장 유사한 구조를 가진 연구이다.</p>
	<p>본 과제와의 차이점</p>	<p>적용 분야의 차이 (VFSS vs Spine Segmentation) 때문에 직접적인 비교는 모호하지만 방법론을 어느정도 적용시킬 수 있었다.</p>
	<p>문헌명 및 저자</p>	<p>Deep High-Resolution Representation Learning for Visual Recognition - Jingdong Wang, Ke Sun, Tianheng Cheng, ...</p>
	<p>문헌의 핵심내용</p>	<p>배경: 기존의 Visual Recognition 모델들은 고해상도 표현이 중요한 역할을 하게된다. 하지만 최근 모델들은 저해상도 표현으로 인코딩하고, 다시 고해상도로 복원하는 구조를 가진다. 해당 연구에선 고해상도 표현을 병렬적으로 유지하면서 정보 교환을 통해 더 정밀한 공간적 표현을 제공한다.</p> <p>주요 특성: 병렬 구조: 고해상도부터 저해상도 모두 컨볼루션 stream 을 병렬적으로 연결한다.</p> <p>정보 교환: 해상도 간의 정보를 반복적으로 교환하여 더 풍부한 의미와 더 정밀한 공간적 표현을 생성한다.</p> <p>결과: 인간 포즈 추정, 의미론적 분할, 객체 감지 등의 분야에서 기존</p>

	<p>의 방법론들보다 더 나은 성능을 보여주었다.</p> <p>결론: HRNet은 고해상도 표현을 유지한다는 점에서 혁신적인 구조를 가지고 있고, 다양한 visual recognition 작업에서 우수한 성능을 보인다.</p>
본 과제와의 공통점	인간 포즈 추정처럼 Key Point를 검출해낼 수 있는 기능으로 뼈의 Key point 를 검출해내는 모델로서 활용할 수 있을 것으로 판단했다.
본 과제와의 차이점	직접 실험해보니 아직 인간 포즈에 한해서 성능이 높은 것으로 보였고, 의학 이미지에 적용 시키기에는 무리가 있는 것으로 판단하여 다른 방법으로 대체하게 되었다.
문헌명 및 저자	Automatic Spine Segmentation and Parameter Measurement for Radiological Analysis of Whole-Spine Lateral Radiographs Using Deep Learning and Computer Vision - Yongtae Kim, Taeseok Jeong, Youngjae Kim, ...
문헌의 핵심내용	<p>배경: Spinopelvic parameter 측정은 척추 기형 진단 및 치료 계획에 중요한 정보를 제공한다. 이 과정을 Mask R-CNN 모델과 컴퓨터 비전 알고리즘을 결합한 자동화된 측정 파이프라인을 제안한다.</p> <p>방법론: Mask R-CNN 모델이 주요 알고리즘으로 사용되었고, 자동으로 측정된 매개변수는 세 명의 외과 의사 수동으로 측정한 매개변수와 통계적으로 비교되었다.</p> <p>결과: 평균 정확도(AP) 96.2%, Dice Score 92.6% 달성하였고, 주요 매개변수의 오차는 PT, LL, SS 는 각각 MAE 1.7, MAE 3.0, ICC 0.94 로 나타났다.</p> <p>결론: 해당 연구는 척추 측면 방사선 사진에서 spinopelvic parameter 를 자동으로 측정할 수 있는 딥러닝 및 컴퓨터 비전 기반의 파이프라인을 제안한다. 이는 높은 정확도와 재현성을 보여주고, 임상 실무에 통합될 수 있다.</p>
본 과제와의 공통점	spinopelvic parameter 측정을 자동화 한다는 부분에서 유사한 연구로 분석된다. 또한 단순 딥러닝 모델만을 사용하는 것이 아닌 컴퓨터 비전 알고리즘을 사용하여 매개변수를 계산하는 것이 유사하다.
본 과제와의 차이점	해당 연구도 본 프로젝트와 같이 2 stage 로 진행되어진다. 그 중 1 stage 인 segmentation 에서 사용한 딥러닝 모델에서 다른 모델을 사용한다. 해당 연구는 Mask R-CNN 을 사용하였고, 본 프로젝트는 TransUNet 을 사용하였다.
문헌명 및 저자	AI-Driven Segmentation and Automated Analysis of the Whole Sagittal Spine from X-ray Images for Spinopelvic Parameter

		Evaluation - Sangyoun Song, Minseok Seo, Changwon Kim, Yunheung Kim, ...
문헌의 핵심내용		<p>연구 방법: 연구는 2015년부터 2022년까지 수집한 932개의 척추 측면 방사선 사진을 사용하였고, train/valid/test 분할은 748/94/90으로 나누어 학습을 진행한다. 딥러닝 모델로는 Mask R-CNN을 사용하여 segmentation을 진행하였다. 모델 성능은 IoU(Intersection over Union)과 AP(평균 정확도) 점수로 평가되었다.</p> <p>결과: 검증 및 테스트 데이터셋에 대해 모델의 AP 점수는 각각 0.614 및 0.586로 측정되었다. AI 모델과 전문가 간의 상호 클래스 상관관계수(ICC)는 대부분의 매개변수에서 높은 신뢰도를 보였다.</p> <p>결론: AI 기반의 딥러닝 모델은 척추 측면 방사선 사진에서 척추-골반 매개변수를 자동으로 감지하고 측정하는 데 있어서 높은 정확도와 효율성을 보였다. 이는 정형외과 진단과 치료 계획의 정확성 및 일관성을 향상시키는 도구가 될 수 있다.</p>
본 과제와의 공통점		해당 연구도 spinopelvic parameter 측정을 자동화 한다는 부분에서 유사한 연구로 볼 수 있다.
본 과제와의 차이점		해당 연구도 본 프로젝트와 같이 2 stage로 진행되어진다. 그 중 1 stage인 segmentation 에서 사용한 딥러닝 모델에서 다른 모델을 사용한다. 해당 연구는 Mask R-CNN을 사용하였고, 본 프로젝트는 TransUNet 을 사용하였다.
문헌명 및 저자		Deep learning approach for automatic landmark detection and alignment analysis in whole-spine lateral radiographs - Yucheng Yeh, Chihung Wengs, Yujui Huang, ...
문헌의 핵심내용		<p>방법론: 딥러닝 모델은 45개의 해부학적 랜드마크(key point)를 자동으로 감지하고, 이를 바탕으로 18개의 방사선 매개변수를 계산한다. Cascaded Pyramid Network(CPN)을 기반으로 한 모델을 사용하였다.</p> <p>결과: key point 감지 정확도와 학습 속도는 경추, 요추, 흉추, 대퇴골 순으로 높았고, 18개의 매개변수 중 15개에서 의사들의 신뢰도를 일치시킬 수 있었다.</p> <p>성과: 이 시스템은 특히 척추의 정렬을 평가하고, 수술 후 추적 관찰을 수행하는데 유용하다. 해당 모델은 경추와 요추 영역은 높은 성능을 보였으나, 흉추와 골반 영역에서는 개선이 필요한 것으로 보인다.</p>
본 과제와의 공통점		해당 연구도 spinopelvic parameter 측정을 자동화 한다는 부분에서 유사한 연구로 볼 수 있다.
본 과제와의		해당 연구는 Segmentation 을 진행하지 않고, 랜드마크를 검출하는

차이점	딥러닝 모델을 사용하였다. 하지만 본 과제에서는 Segmentation에서 딥러닝 모델을 활용하였고, 이후에는 컴퓨터 비전 알고리즘을 통해 key point를 검출하도록 하였다.
문헌명 및 저자	Computer-Aided Diagnosis for Determining Sagittal Spinal Curvatures Using Deep Learning and Radiography - Hyomin Lee, Youngjae Kim, Jebok Cho, ...
문헌의 핵심내용	<p>방법론: 연구에서는 데이터 증강을 사용하여 학습하고, five fold cross-validation 검증 과정을 진행했다. U-Net 기반의 모델을 사용하였고, 매개변수 방정식 및 삼각함수를 이용하여 주요 매개변수를 측정하도록 설계하였다.</p> <p>결과: 모델은 정밀도, 민감도, Dice 점수로 평가하고, 각각 90.53%, 89.53%, 90.22% 의 성능을 보였다. 완성된 알고리즘의 성능은 Pearson 상관 분석, ICC 등의 분석을 통해 검증되었다.</p> <p>결론: 해당 시스템은 척추 시상면 만곡을 분석하고 진단하는데 있어서 관찰자 기반의 변동성을 줄이고 시간과 노력을 절감할 수 있었다.</p>
본 과제와의 공통점	U-Net 기반의 Segmentation 모델을 사용하고 알고리즘을 통하여 매개변수를 측정한다는 점에서 유사하다.
본 과제와의 차이점	<p>해당 연구에서는 대퇴골 (Femoral Head) 에 대한 검출이 이루어지지 않고, 그에 따라 일부 매개변수에 대해 측정을 진행하지 않는다.</p> <p>하지만 요추 임플란트나 척추에 직접 삽입된 카테터와 같은 척추를 차단하는 물체가 척추 분할의 학습 과정에 방해가 될 수 있었다. 또한 성능 오류를 일으키는 butterfly vertebra, hemi vertebra, and block vertebra와 같은 congenital deformities로 인해 segmentation 이전 과정에서 정상과 선천적 변형을 분류할 수 있는 분류 기능이 추가되도록 수정되었어야 했다.</p>
문헌명 및 저자	Deep Learning Automates Measurement of Spinopelvic Parameters on Lateral Lumbar Radiographs - John T. Schwartz, BS,a Brian H. Cho, BS,a Peter Tang, ...
문헌의 핵심내용	<p>방법론: segmentation을 위한 딥러닝 알고리즘으로 MultiResUNet을 활용하였다. MultiResUNet 아키텍처에서는 U-Net 구조의 두 컨볼루션 레이어 시퀀스를 MultiRes 블록으로 대체하였고, 단순한 숏컷 연결 대신에 제안된 Res 패스를 사용하였다.</p> <p>결과: MultiResUNet의 학습을 위해 523장, 검증을 위해 130장의 방사선 사진들이 사용되었다. 이후 Segmentation 평가를 위해 163장의 테스트 데이터가 사용되었다. 해당 모델을 테스트 세트에 적용하였을때,</p>

		<p>전체 DSC 0.951, accuracy 0.936을 달성하였다.</p> <p>결론: 해당 알고리즘은 측면 요추 방사선 영상에서 척추-골반 파라미터를 측정하였으며, 정확도가 의료진과 비슷한 수준이었다. 해당 연구를 활용하여 임상 워크플로우를 간소화하거나 척추-골반 파라미터에 대한 대규모 연구를 수행하는 데 사용할 수 있다.</p>
	본 과제와의 공통점	Segmentation 모델을 사용했다는 점과 컴퓨터 비전 알고리즘을 통하여 매개변수를 측정한다는 점에서 유사하다.
	본 과제와의 차이점	<p>TransUNet이 아닌 U-Net 기반의 MultiResUNet을 사용하였다.</p> <p>X-ray 이미지에 척추보조기구가 포함되어 있음에도 신뢰할 수 있는 측정값을 제공하도록 설계되었으나, 수작업으로 라벨링 된 금속 임플란트와 골반 보형물이 포함된 X-ray 이미지가 사용되었으며, 이는 전체 사진의 6.1%를 차지하였다.</p>
	문헌명 및 저자	Taming Transformers for High-Resolution Image Synthesis - Patrick Esser, Robin Rombach, Bjoörn Ommer
	문헌의 핵심내용	<p>방법론: VQGAN은 Vector Quantization (VQ)과 Generative Adversarial Network (GAN)을 결합한 모델로, 고해상도 이미지 생성을 위한 효율적인 방법이다. VQ는 이미지 데이터를 코드북 벡터로 양자화해 간결한 표현을 제공하고, GAN은 생성자와 판별자가 경쟁적으로 학습해 사실적인 이미지를 만든다.</p> <p>결론: VQGAN은 고해상도와 사실적인 이미지 생성을 가능하게 하며, 효율적인 표현 학습과 다양한 비전 작업에 활용될 수 있는 생성형 모델이다.</p>
	본 과제와의 공통점	본 과제에서는 척추보조기구가 포함되지 않은 정상 이미지로만 VQGAN을 학습시켰고, 척추보조기구가 포함된 이미지에서 척추보조기구가 삭제된 이미지를 생성하는데 VQGAN을 사용하였다.
	본 과제와의 차이점	VQGAN은 정상 이미지에 대한 pattern만 학습하였기 때문에, 원본과 100% 동일한 이미지를 재생성하지 못하였고 이후 과정인 각도 측정에서 문제가 생겼다. 따라서 여러 computer vision 알고리즘들을 활용하여 Spine Restoration Network를 구축했다.
활 용 결 과		<p>선행 연구들을 분석해보면 일부는 Segmentation에, 일부는 Key point detection에 중점을 두는 등 다양한 방법론을 제시하였다. 하지만 서론에 언급한 것 처럼 방법론을 정확하게 제시하지 않는다는 점, 공공 데이터가 없다는 점에서 단순 비교는 의미가 없다고 판단하였다. 따라서 논문에서 소개하고 있는 여러 딥러닝 모델을 실험해보며 비교해보았다.</p> <p>본 연구는 spinopelvic parameter 측정을 자동화 하는 것이 목표이다. 단순히 이를</p>

위해서라면 선행 연구들처럼 Key Point Detection 딥러닝 모델을 사용하여 뼈의 중요 위치들을 검출하고 그 위치들을 이용하여 매개변수를 계산하도록 구현할 수 있다. 하지만 key point를 찾는 과정에서 segmentation 결과를 함께 참조하도록 하면 성능을 높일 수 있지 않을까 라는 생각으로 두 가지 모델을 sequential 하게 병합하였고, 두 종류의 딥러닝 모델을 사용하였다.

그러나 연구를 진행하는 과정에서 segmentation 성능이 좋음에도 불구하고 key point detection 모델은 좋은 성능을 내지 못했다. 이를 기점으로 두 번째 stage에서 key point detection 과정을 딥러닝 모델에서 컴퓨터 비전 알고리즘으로 대체하게 되었다. 새로 도입한 방법은 segmentation 결과가 오류 없이 잘 검출된다면 key point를 검출하는데 큰 오차가 없는 것을 확인하였고, 알고리즘을 작성한 이후에는 첫 번째 stage인 segmentation 성능을 높이는데 중점을 두었다.

Segmentation 분야의 딥러닝 모델 중 U-Net은 Medical Image Segmentation 에서 강점을 가진다는 것은 입증된 결과이다. 또한 ViT (Vision Transformer)는 NLP 분야에서 사용되는 Transformer를 컴퓨터 비전에 적용시킨 구조로서 성능은 검증되어있다. 이 두 가지 구조와 CNN 을 결합한 모델이 TransUNet이다. 본 프로젝트는 TransUNet을 base line 모델로 선정하였다.

또한 데이터 전처리 과정에서는 PEGI-Net 에서 사용한 PEN 을 사용하였다. PEN은 여러 전처리 기법들을 사용한 이후 해당 이미지들을 Convolution Layer를 통과시켜 하나의 이미지로 조합하는 역할을 한다. 이 과정에서 5가지 종류의 필터 이미지를 사용하였고, 이 과정에서 성능이 향상되는 것을 볼 수 있었다.

2.2. Review of Industrial Standards and Regulation

관련 산업 표준 (Industrial Standards)

- **ISO 27001 (정보보안 관리 시스템):**

설명: ISO 27001은 정보보안 관리 시스템(ISMS)의 국제 표준으로, 정보보안 리스크 관리 및 보안 통제를 위한 요구사항을 정의한다.

적용 방법: 의료데이터의 안전한 관리를 위해 ISO 27001 표준을 준수한다. 이를 위해 데이터 접근 통제, 암호화, 정기적인 보안 점검 등의 절차를 마련한다.

- **HL7 (Health Level 7):**

설명: HL7은 의료정보 교환 표준으로, 의료기관 간의 데이터 상호 운용성을 높이기 위한 프로토콜 및 메시지 형식을 정의한다.

적용 방법: 의료 데이터 통합 및 교환 시 HL7 표준을 준수하여 데이터의 호환성과 정확성을 보장한다.

- **GDPR (General Data Protection Regulation):**

설명: GDPR은 유럽 연합의 개인정보 보호 규정으로, 개인 데이터의 처리 및 보호에 대한 엄격한 규정을 제시한다.

적용 방법: 유럽 연합 내 거주자의 데이터를 처리할 경우 GDPR을 준수하여 개인의 프라이버시와 데이터 보호를 보장한다.

국내 법령 (Domestic Regulations)

- **개인정보 보호법 (Personal Information Protection Act):**

설명: 개인정보 보호법은 대한민국에서 개인의 개인정보 보호를 위한 법률로, 개인정보의 수집, 이용, 제공, 관리 등의 과정에서 준수해야 할 사항을 규정한다.

적용 방법: 모든 의료데이터의 수집, 저장, 처리 과정에서 개인정보 보호법을 준수하며, 환자의 동의를 얻고 데이터의 무단 사용을 방지한다.

- **의료법 (Medical Service Act):**

설명: 의료법은 의료 서비스 제공 및 의료기관 운영에 관한 법률로, 의료 데이터의 관리와 의료 정보 시스템의 운영에 대한 규정을 포함한다.

적용 방법: 의료 데이터를 관리할 때 의료법의 규정을 준수하며, 데이터의 무단 접근 및 오용을 방지하기 위한 절차를 마련한다.

국제 법령 (International Regulations)

- **HIPAA (Health Insurance Portability and Accountability Act):**

설명: HIPAA는 미국의 의료 정보 보호법으로, 의료 정보의 프라이버시, 보안, 전자전송 규정을 포함한다.

적용 방법: 미국 내 환자의 데이터를 처리할 경우 HIPAA를 준수하여 데이터의 기밀성과 보안을 보장한다.

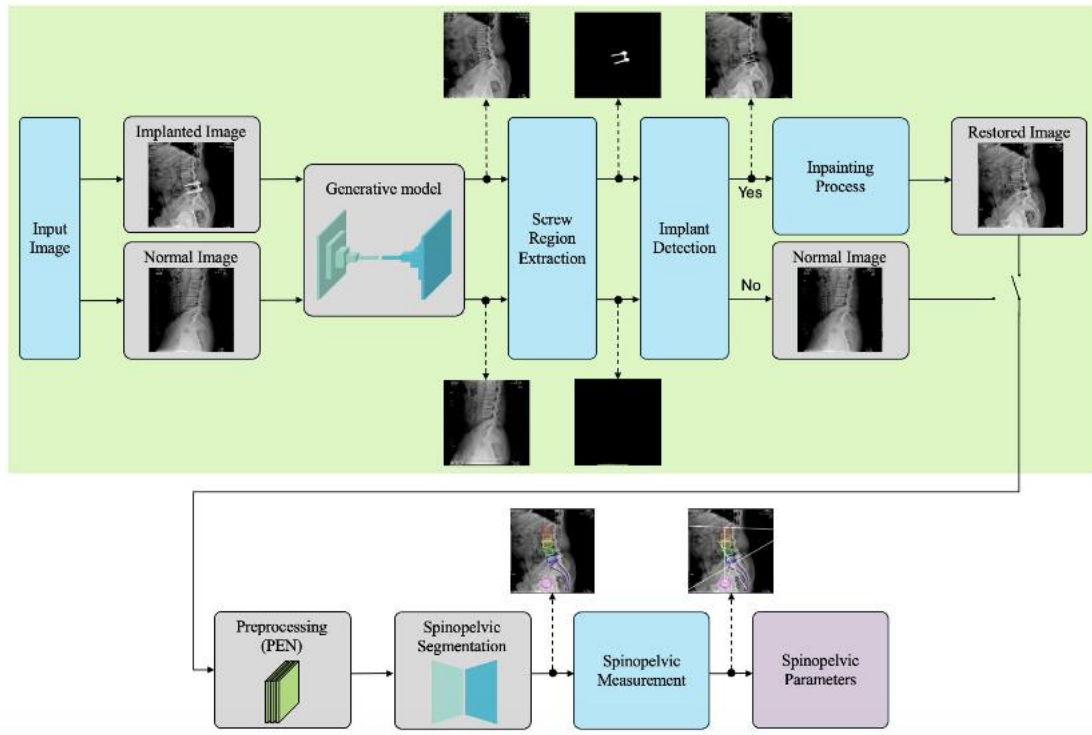
- **ISO 13485 (의료기기 품질 관리 시스템):**

설명: ISO 13485는 의료기기의 품질 관리 시스템에 대한 국제 표준으로, 제품의 설계, 개발, 생산, 설치, 유지보수의 전 과정에서 품질 관리 요구사항을 정의한다.

적용 방법: 사용하는 의료 데이터 시스템이 의료기기로 간주될 경우, ISO 13485를 준수하여 시스템의 안전성과 신뢰성을 확보한다.

3. Proposed Design and Solution

3.1. Overall System Architecture



Spine Restoration Network에서는 생성형 AI를 활용하여 척추 보조기구가 포함된 X-Ray 이미지에서도 척추골반지표를 계산할 수 있도록 하였다. 먼저 VQGAN을 정상 이미지만으로 가지고 학습하여 정상적인 이미지를 재생성할 수 있도록 한다. 이후 학습이 완료된 VQGAN에 척추 보조기구가 포함된 이미지가 입력되면 해당 이미지와 가장 유사하게 생긴 정상적인 이미지를 재생성하게 된다. 이를 통하여 척추 보조기구를 제거할 수 있도록 한다.


Segmentation 작업에는 PEN과 TransUNet 모델이 사용되었다. 먼저 PEN (Preprocessing Ensemble Network)로 모델이 학습에 필요한 이미지 조합을 학습할 수 있도록 하였다. TransUNet 모델은 CNN과 transformer의 장점을 결합한 하이브리드 아키텍처로, 로컬 컨텍스트와 글로벌 컨텍스트를 효과적으로 모델링하여 보다 정확한 localization을 수행한다. CNN은 이미지의 로컬 컨텍스트 정보를 잘 포착하는 반면, transformer는 self-attention 메커니즘을 통해 글로벌 컨텍스트를 모델링하는 데 강력한 성능을 보인다. 이를 통해 TransUNet은 낮은 수준의 세부 정보와 높은 수준의 글로벌 특징을 모두 학습할 수 있어, 더욱 정밀하고 효율적인 의료 영상 segmentation이 가능하다.

Measurement 알고리즘은 Segmentation 결과를 바탕으로 3개의 영역(PT, SS, LL) 각도를 추출하는 것을 목표로 한다. PT 각도는 두개의 femoral heads의 각 중점을 이는 중점에서 Sacrum의 중점과 연결된 직선과, 두개의 femoral heads의 각 중점을 이는 중점에서 y축 방향으로 평행하게 그은 직선과의 각도이다. SS 각도는 두개의 femoral heads의 각 중점을 이는 중점에서 Sacrum의 중점과 연결된 직선과 Sacrum의 상부 종판에 직교하는 직선과의 각도이다. LL은 L1 뼈의 상부 종판을 이은 직선과, Sacrum의 상부 종판을 이은 직선이 이루는 각도이다.

3.2. Detail Design

Spine Restoration Network

척추 X-ray 이미지는 환자들의 척추 질환 진단에 필수적으로 활용된다. 특히, 요추(L1 L5)는 각각의 형태적 유사성 때문에 각 요추를 정확히 식별하기 위해 단순히 생김새뿐 아니라 주변의 해부학적 구조를 고려해야 한다. 그러나 척추에 삽입된 보조기구는 이러한 식별 과정을 복잡하게 만든다. 척추 보조기구는 주로 척추 유합술(Spinal Fusion) 또는 척추 안정화를 목적으로 사용되며, 나사 고정(Pedicle Screw Fixation)과 같은 방법으로 삽입된다. 이러한 보조기구는 퇴행성 디스크 질환, 척추 분리증, 척추 골절 등 다양한 척추 질환 치료 과정에서 흔히 요추(L3 L5)와 천추(S1)에 적용된다. 보조기구는 척추의 안정성을 확보하는 데 중요한 역할을 하지만, 의료 영상 처리에서는 특정 부위를 가리거나 왜곡하여 요추 세그멘테이션 오류를 유발할 수 있다. 이를 해결하기 위해 생성형 모델의 출력을 바로 사용하는 방법이 제안된 바 있으나, 생성형 모델이 생성한 이미지를 직접적으로 활용할 경우 한계가 발생한다. 생성형 모델은 학습 데이터에 기반하여 이미지를 생성하기 때문에, 생성된 이미지에서 전체적인 왜곡이 발생할 가능성이 있다. 특히, GAN 학습 데이터가 부족할수록 이러한 왜곡이 더욱 두드러지게 나타난다.



예를 들어, 그림 (b) GAN Generated 에서 볼 수 있듯이, GAN이 생성한 이미지는 척추 곡률(curvature)과 같은 글로벌 피쳐는 비교적 잘 복원할 수 있다. 그러나 요추의 굴곡과 같은 로컬 피쳐는 학습 데이터의 한계로 인해 정확히 생성되지 않을 수 있다. 이로 인해, 생성된 이미지를 직접 사용할 경우 요추의 굴곡 각도 (segmentation angle)를 추출하는 과정에서 오류가 발생한다. 이러한 한계는 척추의 구조적 특징을 정밀하게 분석해야 하는 의료 영상 처리에서 중요한 문제로 작용한다. 따라서, 본 연구에서는 GAN이 생성한 이미지와 원본 이미지를 결합하여 척추 보조기구 영역 만을 재생성하는 방법을 제안한다. 이를 통해 국소적 피쳐 왜곡 문제를 해결하고, 보다 정확한 척추 세그멘테이션을 가능하게 한다. 구체적으로, 척추 보조기구가 포함되지 않은 이미지를 사용하여 VQ-GAN 을 학습시킨다. 이후, 학습된 모델에 척추 보조기구가 포함된 이미지를 입력으로 제공하면, 모델은 원본 이미지와 유사하지만, 학습 과정에서 본 적이 없는 척추 보조기구는 제거된 형태의 이미지를 생성한다. 이를 활용하면 척추 보조기구로 인한 왜곡 없이 국소적인 피쳐를 복원할 수 있어, 정확한 척추 세그멘테이션을 수행할 수 있다. 제안된 방법은 원본 이미지와 생성 이미지를 함께 사용하여 보조기구 영역을 재구성하며, 이를 통해 의료 영상 처리에서 발생하는 보조기구로 인한 세그멘테이션 오류를 효과적으로 해결한다.

$$x_{reconst} = VQGAN(x)$$

X-ray 이미지에서는 뼈의 윤곽과 보조기구가 상대적으로 높은 픽셀 값을 가지며, 지방층이나 기 타 연조직은 낮은 픽셀 값을 갖는 특징이 있다. 이러한 특성을 활용하여 감마 보정을 적용하면, 밝은 영역과 어두운 영역 간의 대비를 강화하여 각 뼈의 윤곽선을 더욱 뚜렷하게 부각시킬 수 있다. 본 연구에서는 이러한 감마 보정을 활용하여 보조기구 영역을 효과적으로 추출하는 방법을 제안 한다. 구체적으로, 원본 이미지 x 와 VQ-GAN이 생성한 재생성 이미지 $x_{reconst}$ 각각에 감마 보정을 적용한다. 감마 보정은 X-ray 이미지에서 뼈가 아닌 영역의 픽셀 밝기를 감소시켜 검출 대상 영역인 뼈와 보조기구의 대비를 높이는 데 사용된다.

이후, 감마 보정이 적용된 원본 이미지와 재생성 이미지 간의 차이 equation1 를 계산하여 차이나는 영역의 픽셀을 검출한다. 이 차이 이미지는 보조기구와 같은 원본 이미지에만 존재하는 특징을 강조하며, 이를 통해 보조기구 영역을 효과적으로 분리할 수 있다. 이를 통해 척추 보조기구로 인한 세그멘테이션 오류를 완화하고, 보다 정확한 의료 영상 분석이 가능해진다.

$$x_{mask} = OTSU(255 \times \left(\frac{x}{255}\right)^\gamma - 255 \times \left(\frac{x_{reconst}}{255}\right)^\gamma) \quad (1)$$

이 마스크 x 는 임플란트 영역을 강조하며, 이후 inpainting에 사용된다. 보간 과정은 Telea 알고리즘을 따르며, 가중치 기반의 inpainting을 통해 누락된 픽셀을 채운다. 보간된 픽셀 p 의 intensity $I(p)$ 는 다음과 같이 계산된다:


$$I(p) = \frac{\sum_{q \in B_{\epsilon}(p)} w(p, q) [I(q) + \nabla I(q) \cdot (p - q)]}{\sum_{q \in B_{\epsilon}(p)} w(p, q)}$$

where:

- $I(p)$ is the intensity of the inpainted pixel p ,
- $I(q)$ is the intensity of a neighboring pixel q ,
- $\nabla I(q)$ is the gradient of the image at pixel q ,
- $(p - q)$ is the distance between pixels p and q ,
- $w(p, q)$ is the weighting function that gives more influence to neighboring pixels,
- $B_{\epsilon}(p)$ is the neighborhood of pixel p .

감마 보정, Otsu 임계값 처리, 그리고 inpainting을 결합한 이 프로세스는 임플란트 제거와 원본 이미지 구조 복원을 효과적으로 수행할 수 있도록 한다.

Segmentation




척추 X-ray 이미지는 몇 가지 한계점을 가지고 있다. 시상면에서 촬영된 Pelvic 영역은 오른쪽과 왼쪽 Pelvic이 겹쳐 구분이 명확하지 않으며, 환자의 지방 분포로 인해 요추 영역이 얼룩진 패턴으로 나타나는 경우도 있다. 특히, 대비를 높이기 위해 CLAHE를 단독으로 적용할 경우 하반신 영역의 명도가 과도하게 증가하여 Pelvic 구분이 어려워지는 문제가 발생한다. 모델이 학습에 가장 적합한 전처리 조합을 선택하여 사용할 수 있도록 하는 PEN(Pre processing Ensemble Network)을 사용하였다. PEN(Original, CLAHE, Double CLAHE, Sharpening and CLAHE, Sharpening and Double CLAHE, Contrast Stretching 총 6가지 전처리 기법을 적용하여 모델에 인풋으로 입력 하였다. 이 과정에서 서로 다른 전처리 방법으로 생성된 다양한 이미지를 모델이 학습할 수 있도록 구성하여, 각 전처리 방법들의 장단점을 보완하여 다양한 이미지 필터 연산간에 상보적으로 작용하여 모델에게 최적의 정보를 전달할 수 있도록

하였다. 해당 PEN 논문에서는 활성화 함수로 ReLU를 제안하였으나, ReLU는 출력값이 음수인 경우 이를 0으로 변환하여 데이터 손실이 발생하는 한계가 있었다. 이에 본 연구에서는 Leaky ReLU를 사용하여 이러한 데이터 손실을 줄이고, 전처리 단계에서 다양한 정보를 유지할 수 있도록 하였다. 이와 같은 전처리 기법의 활용은 척추 X-ray 이미지에서 발생하는 문제를 해결하고 세그멘테이션 성능을 효과적으로 향상시키는 데 기여할 수 있다. 전처리된 이미지는 TransUNet을 활용하여 세그멘테이션 작업을 수행하였다. TransUNet은 ImageNet으로 사전 학습된 CNN 백본 네트워크를 기반으로 특징을 추출하며, 추출된 특징에 대해 Transformer 기반의 어텐션 연산을 수행하여 고해상도 세부 정보와 글로벌 컨텍스트를 결합하는 모델이다. TransUNet의 출력은 요추(L1-L5), 천골(Sacrum), 대퇴골두(Femoral Head)를 포함한 척추의 다양한 해부학적 영역을 나타내는 8개의 채널로 구성된다. 세그멘테이션 성능 평가는 예측된 세그멘테이션 마스크와 실제 마스크 간의 중첩 정도를 측정하는 Dice Similarity Coefficient (DSC)를 사용하였다. 이를 통해 각 전처리 기법과 TransUNet의 성능을 비교 분석하였으며, 효율적인 전처리 기법의 조합을 도출하였다.

Spinopelvic Parameter estimation

우리는 요추, 천골, 허벅지 뼈에 대하여 서로 다른 알고리즘을 적용시켜 spinopelvic parameter에 필요한 뼈의 종판과 점을 식별하였다. 요추에 대해서는 다음과 같은 알고리즘을 사용하였다. 각 뼈들에서 뼈의 종판을 토대로 lumbar lordosis, segmental angle 등을 식별하였다.



Algorithm 1 Lumbar keypoint detection

```
1: Input: Binary lumbar segmentation image  $img$ 
2: Output: lumbar key points  $L\_TL[0], L\_BR[1], L\_BL[0], L\_TR[1]$ 
3:
4: Find the leftmost point:  $current\_leftmost \leftarrow \operatorname{argmin}_x(lumbar)$ 
5: Compute distances from  $current\_leftmost$  to all points in  $lumbar$ 
6: Find the farthest point:  $farthest\_point \leftarrow \operatorname{argmax}_d(distances)$ 
7:
8: for  $i = 1$  to 4 do
9:   Compute distances from  $farthest\_point$  to all points in  $lumbar$ 
10:  Find the next farthest point:  $farthest\_point \leftarrow \operatorname{argmax}_d(distances)$ 
11:  Append  $farthest\_point$  to  $list\_f$ 
12: end for
13:
14: Initialize  $max\_dist \leftarrow -1, max\_dist\_point \leftarrow \text{None}$ 
15: Define  $tmp \leftarrow [list\_f[2], list\_f[3]]$ 
16: for each point  $point$  in  $lumbar$  do
17:   Compute distance  $d$  from  $point$  to line defined by  $tmp$ 
18:   if  $d > max\_dist$  then
19:     Update  $max\_dist \leftarrow d, max\_dist\_point \leftarrow point$ 
20:   end if
21: end for
22:
23: Compute distances from  $max\_dist\_point$  to all points in  $lumbar$ 
24: Find the farthest point:  $farthest\_point \leftarrow \operatorname{argmax}_d(distances)$ 
25: Initialize  $list\_s \leftarrow []$ 
26:
27: for  $i = 1$  to 4 do
28:   Compute distances from  $farthest\_point$  to all points in  $lumbar$ 
29:   Find the next farthest point:  $farthest\_point \leftarrow \operatorname{argmax}_d(distances)$ 
30:   Append  $farthest\_point$  to  $list\_s$ 
31: end for
32:
33: Return  $list\_s[0], list\_s[1], list\_f[0], list\_f[1]$ 
```

Algorithm 2 Sacrum Key Point Detection

- 1: **Input:** Binary sacrum segmentation image img
 - 2: **Output:** Restored sacrum key points $restored_c.l$, $restored_c.r$
 - 3: Rotate the image by 20 degrees:
 - 4: Compute rotation matrix M for 20°
 - 5: Apply M to img using `warpAffine` to get $rotated_img$
 - 6: Identify sacrum key points:
 - 7: Find leftmost point: $c.l \leftarrow$ Point with smallest x in $sacrum_contour$
 - 8: Find rightmost point: $c.r \leftarrow$ Point with largest y in $sacrum_contour$
 - 9: Rotate key points back to the original orientation:
 - 10: Compute inverse rotation matrix M_{inv} for -20°
 - 11: Transform $c.l$ and $c.r$ using M_{inv} to get $restored_c.l$ and $restored_c.r$
 - 12: Convert restored points to integer format
 - 13: **Return** $restored_c.l, restored_c.r$
-

Algorithm 3 Find Femoral Head Centroid

- 1: **Input:** Binary femoral head mask $mask$
 - 2: **Output:** Centroid of femoral head $centroid$
 - 3: Compute moments of $mask$: $M \leftarrow cv.moments(mask)$
 - 4: Calculate centroid:
 - 5: $cx \leftarrow \frac{M['m10']}{M['m00']}$
 - 6: $cy \leftarrow \frac{M['m01']}{M['m00']}$
 - 7: $centroid \leftarrow (cx, cy)$
 - 8: **Return** $centroid$
-

4. Implementation and Evaluation

4.1. Implementation(구현)

4.1.1. 구현에 사용된 개발 도구

Labelme

- 설명: Image Polygonal Annotation with Python (polygon, rectangle, circle, line, point and image-level flag annotation).
- 목적: 의료 데이터 라벨링을 위하여 사용

Pytorch

- 설명: PyTorch는 신경망 구축에 사용되는 소프트웨어 기반 오픈 소스 딥 러닝 프레임워크로, Torch의 백엔드 머신 러닝 라이브러리와 Python 기반의 고급 API를 결합한 것이다.
- 목적 : 모델 학습 및 아키텍처 변경을 위하여 사용

OpenCV

- 설명: OpenCV 는 Open Source Computer Vision 의 약자로 영상 처리에 사용할 수 있는 오픈 소스 라이브러리이다.
- 목적: Segmentation outputs 을 바탕으로 Post-Processing(후처리) 작업을 위하여 사용

Tmux

- 설명: tmux는 사용자가 단일 단말기 창 또는 원격 터미널 세션 안에서 여러 별도의 터미널 세션에 액세스할 수 있도록 여러 가상 콘솔을 다중화하는데 사용할 수 있는 응용 소프트웨어이다. 이 응용 프로그램은 명령어 인터페이스로부터 다수의 프로그램을 처리하고 유닉스 셸로부터 프로그램을 분리하는 데에 유용하다.
- 목적 : 모델 학습

Tensorboard

- 설명: TensorBoar 는 머신러닝 실험을 위한 시각화 툴킷(toolkit)이다. TensorBoard 를 사용하면 손실 및 정확도와 같은 측정 항목을 추적 및 시각화하는 것, 모델 그래프를 시각화하는 것, 히스토그램을 보는 것, 이미지를 출력하는 것 등이 가능하다.
- 목적: 모델 학습 현황 분석 및 평가

4.1.2. 구현 환경

GPU

- 모델 학습을 위하여 8 개의 8GB GTX 1080 그래픽 카드와 2 개의 24GB TITAN RTX 사용

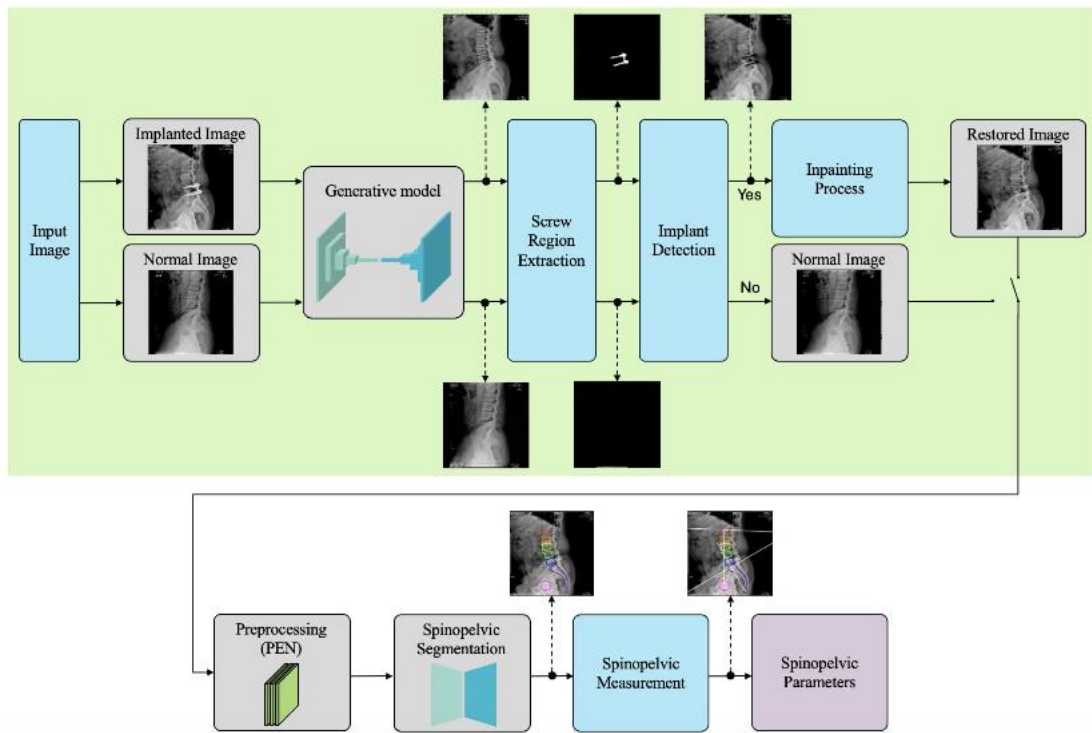
Linux Server

- 모델 학습을 위하여 DEEP LAB 200번 / 8번 서버 사용

Mac OS

- 데이터 전처리를 하기 위하여 Mac OS 환경 사용

4.1.3. 구현 결과



최초의 목표는 Spinopelvic Segementation 및 Spinopelvic Measurement를 통한 Spinopelvic Parameter 계산이었다. 하지만 Spine Restoration Network 개발하여 척추보조기구가 포함된 이미지에서도 Spinopelvic Parameter를 계산하였다는 점에서 목표 대비 구현물의 완성도가 높다. 더불어 Hspine (Graphical User Ineterface)를 의료진에게 제공하여 실제 임상에서 활용되고 데이터 수집에 도움이 되었다는 점에서 기능의 동작도 원활하다고 볼 수 있다. 이번 연구의 Nobility는 Unlabeled Normal data를 활용하여 척추기구가 포함된 이미지에서도 각도 값을 추출했다는 결과이다.

4.2. Experimental Setup

4.2.1 실험 방법

- PEN (Preprocessing Ensemble Network 사용하기 전후 Segmentation 성능 비교
- Spine Restoration Network 사용하기 전후 Segmentation 성능 비교
 - Segmentation with TransUNet
 - Segmentation with UNet
 - Segmentation with SwinUNet
- TransUNet 의 Segmentation 성능 확인
- 자동 측정된 Spinopelvic Parameter 과 의료진이 측정한 Spinopelvic Parameter 비교

4.2.2 Dataset

- TransUNet 학습용
 - Train: 1025 (Normal Image)

- Validation: 119 (Normal Image)
- Test: 150 (Normal Image)

- VQGAN 학습용
 - Train: 1532 (Normal Image, Unlabeled)
 - Test: 183 (Implanted Image)

4.2.3 Ground Truth data (Spine Mask)

- 학생 연구원이 직접 라벨링을 한 450 장의 이미지와, 의료 종사자가 라벨링을 한 875 장의 이미지를 기반으로 평가 및 학습이 진행되었다.
- 학생 연구원이 직접 라벨링을 한 이미지들은 전문의료인의 교육과 피드백을 통해 여러 차례 검수 되었다.

4.2.4 Ground Truth data (Spinopelvic Parameter)

	Pearson
Disc_height	0.973334194
Lordotic_angle	0.979097202
Segmental_angle	0.960229357
Pelvic_incidence	0.978832039
Sacral_slope	0.963093629
PI-LL	0.979493245

<IOU results>

- 2 명의 의료인이 직접 측정한 151 장의 Spinoeplvic Parameter Ground Truth data 를 사용하였다.
- 두 측정자 사이의 Pearson 상관계수는 평균 0.97 이다.

4.3. Evaluation (설계평가)

4.3.1 성능 실험

TransUnet 모델은 GTX 1080 GPU에서 1025장의 이미지로 학습되었고 150장의 이미지로 평가되었다. VQGAN 모델은 GTX TITAN RTX GPU에서 1532장의 unlabeled normal 이미지로 학습되었고, 183장의 이미지로 평가되었다. 본 연구에서 제안하는 Spinopelvic Parameter 측정 자동화 모델은 151장의 Ground Truth data를 사용하여 평가되었다.

4.3.2 성능 평가


Segmentation of TransUNet with various preprocessing algorithms

	Identity	CLAHE	equal_hist	PEN_6
L1	0.89429	0.88973	0.88973	0.89906
L2	0.93041	0.92189	0.92189	0.92186
L3	0.94180	0.94007	0.94007	0.93540
L4	0.94609	0.95478	0.95478	0.95579
L5	0.94923	0.94729	0.94729	0.94589
Sacrum	0.92864	0.93371	0.93371	0.93146
F1	0.90824	0.90760	0.90760	0.91238
F2	0.92286	0.91874	0.91874	0.92863
Average	0.92769	0.92673	0.92673	0.92881

Segmentation of TransUNet with Normal Images

	Dice Score
L1 Mean_dice	0.89
L2 Mean_dice	0.92
L3 Mean_dice	0.94
L4 Mean_dice	0.95
L5 Mean_dice	0.94
Sacrum Mean_dice	0.93
F1 Mean_dice	0.91
F2 Mean_dice	0.92
Average	0.93

※ DSC란?



DSC는 0~1 값을 가지며

1에 가까울 수록 높은 유사도를 의미

Spinopelvic Parameter Measurement

	PT	SS	LL
절대오차	1.377	3.272	4.421
표준편차	± 2.876	± 2.750	± 3.752

Segementation of TransUNet with Implanted Image (Restored Image는 Spine Restoration Network를 활용하여 재생성된 이미지)

Class	Implanted Image	Restored Image	성능 개선
L1	0.83	0.80	-3.61%
L2	0.79	0.88	11.39%
L3	0.78	0.86	10.26%
L4	0.75	0.87	16.00%
L5	0.65	0.84	29.23%
Sacrum	0.64	0.81	26.56%
Femoral Head 1	0.86	0.85	-1.16%
Femoral Head 2	0.86	0.86	-0.65%
average	0.77	0.85	10.39%

Segementation of UNet with Implanted Image (Restored Image는 Spine Restoration Network를 활용하여 재생성된 이미지)

	Implanted	Restored	Difference
L1	0.84	0.76	-8.50%
L2	0.73	0.75	+3.21%
L3	0.80	0.82	+1.70%
L4	0.81	0.81	+0.21%
L5	0.66	0.71	+7.82%
Sacrum	0.62	0.65	+4.23%
F1	0.87	0.84	-4.01%
F2	0.85	0.82	-4.15%
Average	0.7720	0.7688	-0.41%

Segementation of SwinUNet with Implanted Image (Restored Image는 Spine Restoration Network를 활용하여 재생성된 이미지)

	Implanted	Restored	Difference
L1	0.79	0.75	-5.06%
L2	0.66	0.58	-12.12%
L3	0.67	0.61	-8.96%
L4	0.66	0.70	+6.06%
L5	0.57	0.73	+28.07%
Sacrum	0.63	0.73	+15.87%
F1	0.83	0.79	-4.82%
F2	0.78	0.74	-5.13%
Average	0.6979	0.7017	+0.54%

4.3.3 기능 평가

TransUnet 모델은 척추 매개변수 자동화 측정에서 효과적인 성능을 보였다. 각 클래스에 대한 세부 정보와 글로벌 컨텍스트를 모두 학습하여 정확한 segmentation을 수행하였다. 특히, Cage & Screw가 포함되어 있는 Implanted Image에서도 Spinopelvic Parameter를 정확하게 측정하는 데 있어 기존 연구들과 비교하여 독창적인 방법론을 제시하였다 (Spine Restoration Network). 더불어 Hspine (Graphical User Interface) 개발을 통해 임상에서 수용 가능할 수준의 오차를 보이는 자동화 기술을 손쉽게 사용 가능하도록 만들었다.

5. CONCLUSION

본 프로젝트는 척추-골반 측정의 자동화를 목표로 하여 의료 영상 분석의 효율성과 일관성을 향상시키기 위해 추진되었다. X-ray 영상에서 척추 segmentation과 Spinopelvic Parameter를 자동으로 추출하고, 척추 보조기구로 인한 방해 요소를 제거하는 Spine Restoration Network를 개발하였다. 또한, Hspine이라는 사용자 친화적인 GUI를 통해 임상 환경에서 딥러닝 모델의 실질적인 활용 가능성을 확인했다.

실험 결과, PT, SS, LL 각도의 평균 절대 오차가 허용 가능한 표준 편차 범위 내에 있어 높은 정확도를 입증하였으며, 척추 보조기구 제거를 통해 segmentation 성능이 10.39% 향상되었다. GUI는 의료 전문가들이 프로그래밍 지식 없이도 쉽게 사용할 수 있도록 설계되어, 임상 환경에서의 실용성을 높였다. 이러한 성과는 2024 공학페스티벌 특별상 및 창의적 종합설계 경진대회 은상 수상으로 이어졌으며, 관련 논문 작성 또한 진행 중이다.

본 프로젝트의 의의는 딥러닝 기반 의료 영상 분석의 자동화를 통해 진단의 효율성과 정확성을 향상시키고, 의료진의 작업 부담을 줄이며, 환자 맞춤형 치료 계획 수립을 지원하는 데 있다.

향후 과제는 다음과 같다.

다양한 데이터셋 확보 및 일반화 성능 개선:

- 더 많은 환자 데이터를 수집하여 다양한 척추 상태에 대한 모델의 강건성을 강화.
- 새로운 병변이나 보조기구가 포함된 데이터셋으로 성능을 검증.

Spine Restoration Network 개선:

- 보조기구 제거 후 생성 이미지와 원본 간의 불일치를 줄이기 위한 추가적인 학습 및 복원 알고리즘 개선.

다양한 의료영상 형식 지원:

- X-ray뿐만 아니라 CT 및 MRI 영상으로 범위를 확장하여 적용 가능성을 확대.

6. REFERENCES

6.1. 기술표준문서, 특허 및 참고논문

- Chen, J., Lu, Y., Yu, Q., Luo, X., Adeli, E., Wang, Y., Lu, L., Yuille, A. L., & Zhou, Y. (2021, February 8). TransUNet: Transformers Make Strong Encoders for Medical Image Segmentation. arXiv.org. <https://arxiv.org/abs/2102.04306>
- Mushtaq, M., Akram, M.U., Alghamdi, N.S., Fatima, J., & Masood, R.F. (2022). Localization and Edge-Based Segmentation of Lumbar Spine Vertebrae to Identify the Deformities Using Deep Learning Models. *Sensors* (Basel, Switzerland), 22.
- Schwartz, J. T., Cho, B. H., Tang, P., Schefflein, J., Arvind, V., Kim, J. S., Doshi, A. H., & Cho, S. K. (2021). Deep learning automates measurement of spinopelvic parameters on lateral lumbar radiographs. *Spine*, 46(12), E671–E678. <https://doi.org/10.1097/BRS.0000000000003830>
- Orosz LD, Bhatt FR, Jazini E, Dreischarf M, Grover P, Grigorian J, Roy R, Schuler TC, Good CR, Haines CM. Novel artificial intelligence algorithm: an accurate and independent measure of spinopelvic parameters. *J Neurosurg Spine*. 2022 Jul 8;37(6):893-901. doi: 10.3171/2022.5.SPINE22109. PMID: 35901700.
- Ibtehaz, N., & Rahman, M. S. (2020). MultiResUNet: Rethinking the U-Net architecture for multimodal biomedical image segmentation. *Neural Networks*, 121, 74–87. <https://doi.org/10.1016/j.neunet.2019.08.025>
- Lee, H. M., Kim, Y. J., Cho, J. B., Jeon, J. Y., & Kim, K. G. (2022). Computer-Aided Diagnosis for Determining Sagittal Spinal Curvatures Using Deep Learning and Radiography. *Journal of Digital Imaging*, 35(4), 846–859. <https://doi.org/10.1007/s10278-022-00592-0>
- N., & Rahman, M. S. (2020). MultiResUNet: Rethinking the U-Net architecture for multimodal biomedical image segmentation. *Neural Networks*, 121, 74–87. <https://doi.org/10.1016/j.neunet.2019.08.025>
- Song SY, Seo MS, Kim CW, Kim YH, Yoo BC, Choi HJ, Seo SH, Kang SW, Song MG, Nam DC, Kim DH. AI-Driven Segmentation and Automated Analysis of the Whole Sagittal Spine from X-ray Images for Spinopelvic Parameter Evaluation. *Bioengineering* (Basel). 2023 Oct 20;10(10):1229. doi: 10.3390/bioengineering10101229. PMID: 37892959; PMCID: PMC10604000.
- Kim YT, Jeong TS, Kim YJ, Kim WS, Kim KG, Yee GT. Automatic Spine Segmentation and Parameter Measurement for Radiological Analysis of Whole-Spine Lateral Radiographs Using Deep Learning and Computer Vision. *J Digit Imaging*. 2023 Aug;36(4):1447-1459. doi: 10.1007/s10278-023-00830-z. Epub 2023 May 2. PMID: 37131065; PMCID: PMC10406753.
- Cina, A., Bassani, T., Panico, M. et al. 2-step deep learning model for landmarks localization in spine radiographs. *Sci Rep* 11, 9482 (2021).

<https://doi.org/10.1038/s41598-021-89102-w>

- Tragakis, A., Kaul, C., Murray-Smith, R., & Husmeier, D. (2022, June 1). The Fully Convolutional Transformer for Medical Image Segmentation. arXiv.org. <https://arxiv.org/abs/2206.00566v2>
- Long, J., Shelhamer, E., & Darrell, T. (2014, November 14). Fully Convolutional Networks for Semantic Segmentation. arXiv.org. <https://arxiv.org/abs/1411.4038>
- Ronneberger, O., Fischer, P., & Brox, T. (2015, May 18). U-Net: Convolutional Networks for Biomedical Image Segmentation. arXiv.org. <https://arxiv.org/abs/1505.04597>
- He, K., Gkioxari, G., Dollár, P., & Girshick, R. (2017, March 20). Mask R-CNN. arXiv.org. <https://arxiv.org/abs/1703.06870>
- Wang, J., Sun, K., Cheng, T., Jiang, B., Deng, C., Zhao, Y., Liu, D., Mu, Y., Tan, M., Wang, X., Liu, W., & Xiao, B. (2019, August 20). Deep High-Resolution Representation Learning for Visual Recognition. arXiv.org. <https://arxiv.org/abs/1908.07919>
- Park, D., Kim, Y., Kang, H., Lee, J., Choi, J., Kim, T., Lee, S., Son, S., Kim, M., & Kim, I. (2024). PECl-Net: Bolus segmentation from video fluoroscopic swallowing study images using preprocessing ensemble and cascaded inference. *Computers in Biology and Medicine*, 172, 108241. <https://doi.org/10.1016/j.compbiomed.2024.108241>

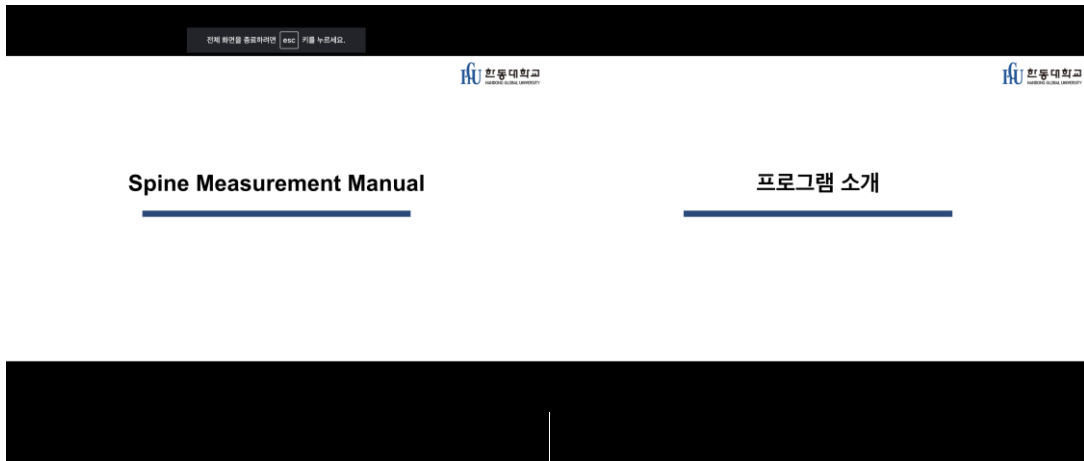
Appendix :

Part A 공동작성

A.1 How to Use It

Google Slide HSpine 사용설명서 및 데모영상

전체 화면을 종료하려면 **esc** 키를 누르세요.



The image shows the main interface of the HSpine software. It features a dark background with a central area for spine measurement. The top bar includes a button to exit the full screen (esc key). The interface is divided into two main sections: 'Spine Measurement Manual' on the left and '프로그램 소개' (Program Introduction) on the right.

Spine Measurement Manual

Spine Measurement는 환자의 척추 이미지로 부터 spinopelvic parameter (pelvic tilt, sacral slope, lumbar lordosis)를 자동으로 계산하는 프로그램 입니다.

척추 이미지로 부터 segmentation map을 추출하고 추출한 segmentation map을 바탕으로 computer vision algorithm을 활용하여 spinopelvic parameter를 자동으로 계산합니다.

프로그램 소개

The image shows the '프로그램 소개' (Program Introduction) section. It contains a brief description of the software's purpose and a list of features. The text is in Korean and describes the software's ability to automatically calculate spinopelvic parameters from spine images.

프로그램 구성

The image shows the '프로그램 구성' (Program Structure) section. It displays a list of files and folders in a table. The files include 'Spine Measurement Manual.docx', 'Spine Measurement Manual.pdf', and 'Spine Measurement Program.exe'. The 'Spine Measurement Program.exe' file is highlighted with a red box.

프로그램 구성

The image shows the '프로그램 구성' (Program Structure) section. It displays a list of files and folders in a table. The files include 'Spine Measurement Manual.docx', 'Spine Measurement Manual.pdf', and 'Spine Measurement Program.exe'. The 'Spine Measurement Program.exe' file is highlighted with a red box.

해당 파일 압축 풀기

해당 폴더에 접속 후 주소창에 cmd 입력 후 엔터

각도 계산 결과 창


사용 방법

사용 방법

- 각도 계산
- 보조 도구
- 각도 수정

사용 방법 - 각도 계산

사용 방법 - 각도 계산



업로드용 이미지 드래그

사용 방법 - 각도 계산



각도 계산 버튼 클릭

사용 방법 - 각도 계산




각도 계산 결과 확인

사용 방법 - 각도 계산



프로그램 리셋 버튼 클릭

사용 방법 - 각도 계산



업로드용 이미지 드래그 (반복)

사용 방법 - 보조 도구

사용 방법 - 보조 도구




보조 도구 - Segmentation 옵션

사용 방법 - 보조 도구



보조 도구 - Point 옵션


사용 방법 - 보조 도구



보조 도구 - Line 옵션

사용 방법 - 각도 수정

사용 방법 - 각도 수정




수정할 점 주변 클릭 (지정된 점 파란색으로 변경됨)

사용 방법 - 각도 수정

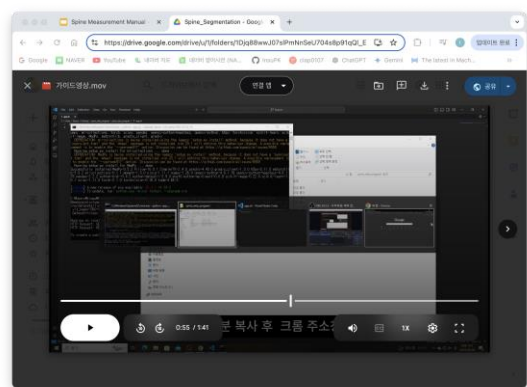


원하는 지점 클릭 (지정된 점 원하는 지점으로 이동함)

사용 방법 - 각도 수정



수정된 각도 확인



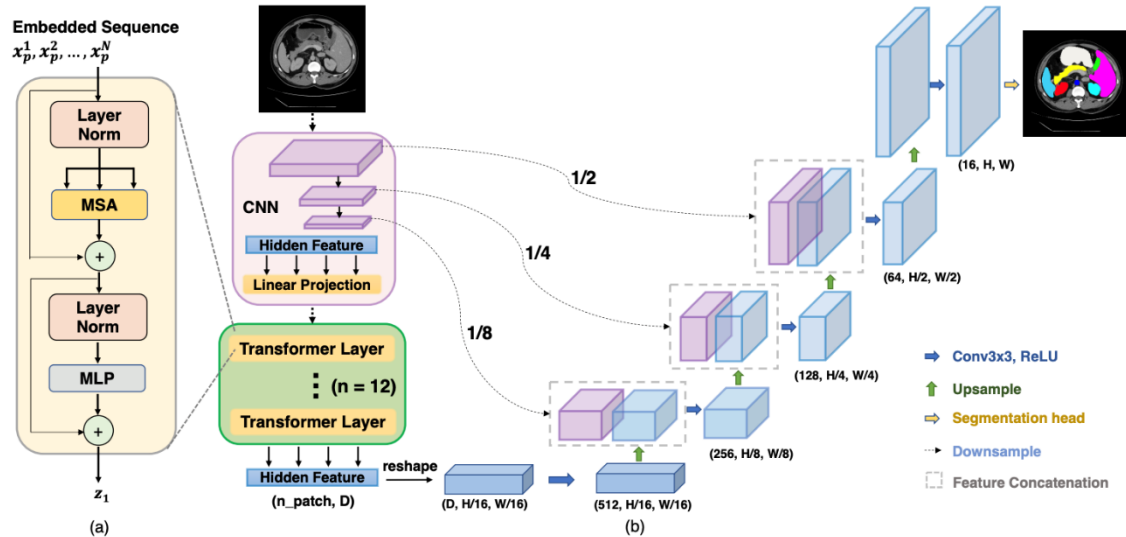
A.2 상세설계 및 소스코드 블록도 설명

A.2.1 소스코드 파일 구조

<ul style="list-style-type: none"> TransUNet <ul style="list-style-type: none"> __pycache__ lists/lists_Spine <ul style="list-style-type: none"> test.txt train.txt val.txt logs networks <ul style="list-style-type: none"> __pycache__ vit_seg_configs.py vit_seg_modeling_resnet_... vit_seg_modeling.py draw.py infer.sh line.ipynb test.py train.py trainer.py utils.py 	<ul style="list-style-type: none"> 프로젝트 작업 디렉토리 - 데이터셋 분류를 위한 디렉토리 테스트 데이터셋 리스트 훈련 데이터셋 리스트 검증 데이터셋 리스트 학습 과정 모니터링을 위한 tensorboard log 모델 구조를 위한 디렉토리 - ViT configuration 을 위한 파일 CNN 네트워크 구조 설계 전체 모델 구조 설계 Spinopelvic parameter를 계산하는 파이썬 코드 코드 실행을 위한 쉘 스크립트 파일 시각화를 위한 주피터 노트북 코드 테스트 실행을 위한 선언 코드 훈련 실행을 위한 선언 코드 실질적인 훈련이 진행되는 파이썬 코드 실질적인 테스트가 진행되는 파이썬 코드
------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------	-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------

A.2.2 소스 코드 설명

Segmentation (TransUNet)



TransUNet은 크게 CNN backbone network (이하 CNN) 와 Encoder, Decoder로 나뉘어진다. 입력 데이터가 TransUNet에 들어가면 CNN 에서 feature map을 추출한다. 그 이후 Transformer 가 사용된 Encoder에서 feature를 인코딩 하게 되고, 이후 Decoder 부분에서 Upsampling 과 함께 원래의 해상도로 복원시키는 과정을 거친다.

```
class Embeddings(nn.Module):
    def __init__(self, config, img_size, in_channels=3):
        if self.hybrid:
            self.hybrid_model = ResNetV2(block_units=config.resnet.num_layers, width_factor=config.resnet.width_factor)
            in_channels = self.hybrid_model.width * 16
        self.patch_embeddings = Conv2d(in_channels=in_channels,
                                       out_channels=config.hidden_size,
                                       kernel_size=patch_size,
                                       stride=patch_size)
        self.position_embeddings = nn.Parameter(torch.zeros(1, n_patches, config.hidden_size))
        # self.position_embeddings = nn.Parameter(torch.zeros(1, 1024, config.hidden_size))

        self.dropout = Dropout(config.transformer["dropout_rate"])

    def forward(self, x):
        if self.hybrid:
            x, features = self.hybrid_model(x)
        else:
            features = None
        # (B, hidden, n_patches^(1/2), n_patches^(1/2))
        x = self.patch_embeddings(x)

        x = x.flatten(2)
        x = x.transpose(-1, -2) # (B, n_patches, hidden)

        embeddings = x + self.position_embeddings
        embeddings = self.dropout(embeddings)
        return embeddings, features
```

< TransUNet - Embeddings 클래스 >

위의 사진에서 볼 수 있는 Embeddings 클래스는 모델 내에서 가장 먼저 지나게 되는 Layer이다. Embeddings 내에는 CNN과 다음 Layer로 넘어가기 위한 준비 단계를 거친다. 본 프로젝트에서는 CNN으로 ResNet을 사용하였다. 위의 코드에서 hybrid_model은 CNN을 의미한다. hybrid_model을 통하여 입력 이미지에서 feature map을 추출하게 된다. 이후에 진행되는 patch_embeddings 와 flatten과 같은 코드는 해당 feature map을 1차원 임베딩 벡터로 표현하기 위한 layer 이다.

```
class Encoder(nn.Module):
    def __init__(self, config, vis):
        super(Encoder, self).__init__()
        self.vis = vis
        self.layer = nn.ModuleList()
        self.encoder_norm = LayerNorm(config.hidden_size, eps=1e-6)
        for _ in range(config.transformer["num_layers"]):
            layer = Block(config, vis)
            self.layer.append(copy.deepcopy(layer))

    def forward(self, hidden_states):
        attn_weights = []
        for layer_block in self.layer:
            hidden_states, weights = layer_block(hidden_states)
            if self.vis:
                attn_weights.append(weights)
        encoded = self.encoder_norm(hidden_states)
        return encoded, attn_weights

class Block(nn.Module):
    def __init__(self, config, vis):
        super(Block, self).__init__()
        self.hidden_size = config.hidden_size
        self.attention_norm = LayerNorm(config.hidden_size, eps=1e-6)
        self.ffn_norm = LayerNorm(config.hidden_size, eps=1e-6)
        self.ffn = Mlp(config)
        self.attn = Attention(config, vis)

    def forward(self, x):
        h = x
        x = self.attention_norm(x)
        x, weights = self.attn(x)
        x = x + h

        h = x
        x = self.ffn_norm(x)
        x = self.ffn(x)
        x = x + h
        return x, weights
```

Embeddings 에서 반환하는 feature map 은 Encoder 로 입력되어진다. 본 프로젝트에서는 Encoder에서 Block을 12개 사용하게 된다. Block 클래스가 실질적으로 Transformer가 적용되는 부분이다. Block 에서는 Multi Head Self-Attention 을 통해 이미지 패치 간의 상관관계를 파악하고, 이를 통해 전역적인 문맥을 파악할 수 있도록 한다. Block을 모두 지나고 나면 encoded 된 feature map을 추출할 수 있다.

이전 Layer 에서 반환한 feature map은 low resolution, high dimension feature를 갖는다. 해당 feature를 원본 해상도로 키우는 작업과 feature를 조합하여 필요한 Task에 맞게 재조합 하는 과정을 Decoder 부분에서 진행하게 된다. Convolution Layer 와 Upsampling 을 수 차례 거치며 Segmentation 을 진행하게 된다. 이 과정에서는 Embedding에서 사용되었던 CNN의 결과값을 사용하여 원본 이미지의 맥락을 살릴 수 있도록 skip connection을 사용하게 된다.

Spine Restoration Network

```
original = cv.imread(original_dir, cv.IMREAD_GRAYSCALE)
fake = cv.imread(fake_dir, cv.IMREAD_GRAYSCALE)

real_original = cv.imread(original_dir, cv.IMREAD_GRAYSCALE)

original[:, :50] = 0
original[:, 206:] = 0
fake[:, :50] = 0
fake[:, 206:] = 0

gamma_coefficient = 0.35

new_original = adjust_gamma(image=original, gamma=gamma_coefficient)
new_fake = adjust_gamma(image=fake, gamma=gamma_coefficient)

diff = cv.subtract(new_original, new_fake)
ori_diff = diff

kernel = cv.getStructuringElement(cv.MORPH_RECT, (3, 3))
diff = cv.morphologyEx(diff, cv.MORPH_OPEN, kernel)
_, diff = cv.threshold(diff, 0, 255, cv.THRESH_BINARY + cv.THRESH_OTSU)
inpaint = cv.inpaint(real_original, diff, inpaintRadius=5, flags=cv.INPAINT_TELEA)

original = cv.resize(original, (2000, 2000))
cv.imwrite(inpainted_image_path, inpaint)
```

먼저 Cage & Screw가 포함된 Implanted Image를 original 변수에 불러오고 Spine Restoration Network로 Screw를 제거한 Restored Image를 fake 변수에 불러온다. 이후, 환자의 정보가 포함된 메타 데이터를 제거하기 위해 0:50, 206:256의 영역의 픽셀값을 0으로 만들어준다. 이는 노이즈 제거에서 메타 데이터의 값이 다른 픽셀과 비교했을 때 너무 높아 (255) 방해가 되기 때문이다. 이후 gamma_correction을 각각의 이미지에 적용하고 차이를 구한다. 구해진 차이값에 모폴로지 연산, 오토 알고리즘을 적용하여 노이즈를 제거한다. 그렇게 구해진 screw mask를 활용하여 원본이미지에서 screw에 해당하는 픽셀을 제거한 뒤, 주변 픽셀값으로 채워주는 inpainting 알고리즘으로 screw가 제거된 이미지를 최종적으로 생성한다.

A.3 기술적 추가설명

PEN

PEN은 여러 전처리 기법을 결합하여 입력 이미지의 품질을 향상시키는 기법이다.

```
class PEN(nn.Module):
    def __init__(self):
        super(PEN, self).__init__()
        self.conv1 = nn.Conv2d(5, 3, kernel_size=7, stride=1, padding=3)
        self.leakyrelu=nn.LeakyReLU()

    def forward(self, x):
        x = self.leakyrelu(self.conv1(x))
        return x
```

현재 모델에서 사용중인 Dataset은 5가지 혹은 6가지 종류의 전처리 기법이 적용되어있는 입력 데이터로 구성되어있다. 따라서 데이터가 입력되면 5채널 혹은 6채널에서 3채널로 반환해주는 Convolution Layer를 지나게 된다. 이 과정에서 각각의 전처리 기법을 적절히 조합하여 모델에 적합한 입력 데이터를 찾도록 한다. 이 Layer는 hidden layer로 작용하기 때문에 activation function으로는 LeakyReLU를 사용해주었다.

A.4 본 프로젝트에서 생성된 지식재산권

논문 게재 예정

Part B 개인 작성

B.1 Relationship of Individual Project Assignment to Overall Project

각 부분 설계의 기능

- **Data Preparation**
 - 기능: Segmentation Mask 및 Key Points에 대한 마스크 라벨링.
 - 설명: labelme 프로그램을 이용하여 약 500장의 데이터를 라벨링한다.
- **Spine Restoration**
 - 기능: Spine X-ray 이미지에서 screw 제거
 - 설명: Anomaly detection 및 noise 제거 알고리즘을 활용하여 척추보조기구를 제거한다.
- **Re-architected AI Models**
 - 기능: TransUNet 모델의 아키텍처 수정 및 모델 결합.
 - 설명: TransUNet 모델에 여러 기법들을 추가할 방법과 위치를 찾기위해 실험해 보고, 적절한 optimizer, loss function, activation function을 찾기위해 모델을 수정한다.

Design Assignment

이름	작업 내용 요약
	Pre-Processing: 전문의료인의 교육을 받고 약 500장의 데이터에 대해 팀원과 직접 라벨링. 이미지 마스크 및 key points에 대한 라벨링 후 병원 피드백을 반영하여 수정.
	Spine Restoration: 약 1500장의 unlabeled data로 VQGAN을 학습. Noise 제거를 위한 다양한 CV 알고리즘 탐색 및 Inpainting 적용.
	Re-architected AI Models: 기존의 TransUNet에 여러 기법들을 추가하는데 있어서 적합한 Block 및 Layer를 구현하고, 어떤 위치에 추가하면 적합할지 실험을 통해 분석. 또한 기존에 사용하던 loss function, activation function, 모델의 optimizer를 실험해보며 모델 수정.

각 부분 설계의 기능

- **Model-Train**
 - 기능: 데이터 준비 및 모델 학습.
 - 설명: 제공된 데이터에 맞게 각 텐서의 차원을 맞추고 모델을 학습하고, Tensorboard를 이용하여 학습 과정을 모니터링한다.
- **Model-Test**

- 기능: 학습된 모델의 테스트 및 평가.
- 설명: 학습된 모델을 테스트하고 결과를 평가한다. 이상치를 분석하고, 결과를 바탕으로 hyper parameter를 수정하여 재학습한다.

- **Spinopelvic Segmentation + Spinopelvic Measurement**

- 기능: Spinopelvic Parameter 계산.
- 설명: 딥러닝 모델을 이용하여 Segmentation하고, CV 알고리즘으로 Spinopelvic Parameter를 계산한다.

Design Assignment

이름	작업 내용 요약
	Model-Train: 450장의 데이터로 학습을 진행하고, 팀원과 데이터 셋의 분배에 대해 토론. Tensorboard를 이용해 학습 진행 상황을 모니터링.
	Model-Test: 학습된 모델을 테스트하고 이상치를 분석하여 hyper parameter들을 수정.
	Re-architected AI Models: 기존의 TransUNet에 여러 기법들을 추가하는데 있어서 적합한 Block 및 Layer를 구현하고, 어떤 위치에 추가하면 적합할지 실험을 통해 분석. 또한 기존에 사용하던 loss function, activation function, 모델의 optimizer를 실험해보며 모델 수정.

B.2 Economical, Industrial and Social Effects

본 프로젝트는 척추 질환 진단에 필요한 시간과 비용을 절감하고 일관된 결과를 제공함으로써 의료 진단의 정확도를 높이고 효율성을 강화하는 것을 목표로 삼았다. 특히 척추-골반 매개변수 측정을 자동화함으로써 의사의 판단 과정에서 발생할 수 있는 편차를 줄이고, 오진의 가능성을 낮춰 의료 안정성을 크게 향상시킬 수 있을 것으로 기대된다. 이러한 기술적 도입은 의료 분야에서 AI 활용의 새로운 기준을 제시하며, 첨단 의료 시스템 발전에 기여할 것이다.

환경적 영향

진단 과정에서 사용되는 방사선 촬영 장비와 고사양의 컴퓨터 자원 등은 상당한 에너지와 자원을 소모한다. 본 프로젝트에서 개발된 솔루션은 기존의 무거운 의료 소프트웨어 대비 효율적이고 경량화된 AI 모델을 활용해 이러한 자원 소모를 줄이고, 환경적으로도 긍정적인 영향을 미칠 것이다.

사회적 영향

AI 기반의 자동화 진단 시스템은 비용 효율성과 정확도를 동시에 제공할 수 있다. 이를 통해 의료 복지의 접근성이 향상되며, 특히 의료 인력이 부족한 지역에서도 안정적인 의료 서비스를 제공할 수 있을 것으로 기대된다. 이러한 기술적 진보는 사회의 전반적인 건강 수준을 높이고, 모두

가 혜택을 누릴 수 있는 공평한 의료 환경을 조성하는 데 기여할 것이다.

경제적 영향

진단 과정의 시간과 비용을 줄이는 것은 경제적 측면에서도 큰 이점을 제공한다. 의료 서비스 비용의 절감은 더 많은 환자들이 신뢰할 수 있는 의료 서비스를 이용할 수 있도록 돕고, 의료 산업 내 화폐 순환을 원활하게 만들어 경제 전반에 긍정적인 영향을 미칠 것이다. 이는 의료 산업뿐만 아니라 AI 관련 기술의 상업적 활용 가능성도 확대할 것이다.

문화적 영향

AI의 도입이 점점 확산되는 현 시대에서, 본 프로젝트는 AI 기술이 실질적으로 의료에 기여할 수 있음을 증명하는 사례가 될 것이다. 이러한 긍정적인 경험은 AI 기술에 대한 대중의 신뢰를 높이고, 미래 AI 산업의 발전 가능성을 넓히는 데 중요한 역할을 할 것이다. 특히 인간과 AI 간의 협력을 통해 생산성과 효율성이 증대되는 모습을 보여줄 수 있다.

기독교 세계관적 함의

AI를 활용한 의료 기술은 환자의 치료와 돌봄에서 사랑과 배려를 실천하는 도구로 사용될 수 있다. 이는 인간의 본연적 선함을 강조하며, 의료인을 포함한 사회 구성원들에게 더 나은 의료 서비스를 제공하고, 나아가 이웃 사랑의 가치를 실천하는 데 기여할 수 있을 것이다.

결론

AI와 의학의 융합은 한 분야에 국한되지 않고, 양 분야 모두의 발전을 이끌어낼 수 있는 강력한 원동력이 될 것이다. 본 프로젝트는 의료 시스템에 신뢰도를 더할 뿐만 아니라 AI 기술의 실용성과 잠재력을 입증함으로써, 사회 전반에 걸쳐 선한 영향력을 미칠 것이다. 향후 본 프로젝트의 확장과 개선을 통해 AI와 의학이 함께 만들어가는 새로운 의료 패러다임을 구축할 수 있을 것으로 기대된다.

AI 기반 의료 영상 처리는 공정하고 투명한 진단을 가능하게 하여 의료 시스템에 긍정적인 변화를 가져올 것으로 보인다. 척추 매개변수는 척추측만증 진단뿐만 아니라 허리 디스크 및 케이지 삽입 시술 등 다양한 상황에서 중요한 역할을 할 것이다. 이번 연구를 통해 개발된 딥러닝 모델과 알고리즘은 보다 정밀하고 일관된 진단을 제공하여, 의사의 시간적 부담을 줄이는 동시에 환자에게 신뢰할 수 있는 진료를 제공할 것이다. 또한, 과잉 진료를 예방하고 객관적이고 신뢰할 수 있는 진단 체계를 확립하여 사회적으로 긍정적인 영향을 미칠 것이다.

환경적 영향

이 프로젝트는 의료 자원을 효율적으로 사용하여 환경적 부담을 줄이는 데 기여할 것이다. 과잉 진료를 줄이고 불필요한 검사나 시술을 최소화함으로써 의료 폐기물 발생을 줄일 수 있을 것이다. 또한, 정밀한 진단을 통해 환자가 적합한 치료를 빠르게 받을 수 있도록 하여 불필요한 고통을 줄이고 회복 시간을 단축할 것이다.

사회적 영향

AI 기반 진단 기술은 의료 서비스의 정확성과 일관성을 높여 환자들에게 보다 나은 치료를 제공할 것이다. 특히 의료 접근성이 낮은 지역에서는 이러한 기술이 형평성 있는 진료 환경 조성에 크게 기여할 것이다. 이와 함께 의료진의 업무 부담을 줄여 의료 인력의 효율성을 높일 것이다.

경제적 영향

정확한 진단과 효율적 진료는 의료 비용 절감 효과를 가져올 것이다. 불필요한 검사와 시술을 줄임으로써 환자와 의료 보험사의 재정적 부담을 낮출 수 있을 것이다. 또한, AI 기술의 상용화로 관련 산업이 성장할 것이며, 새로운 시장이 형성되어 경제적 발전을 촉진할 것이다.

문화적 영향

AI 기술의 도입은 의료 분야에서의 혁신을 촉진하여 의료진과 환자 모두에게 기술에 대한 신뢰를 높일 것이다. 공정하고 투명한 진단이 가능해짐에 따라 의료 서비스에 대한 사회적 신뢰도도 상승할 것이다. 이러한 변화는 의료 서비스의 새로운 표준을 확립하는 데 기여할 것이다.

기독교 세계관적 함의

이 프로젝트는 사회적 약자를 돕고자 하는 기독교적 가치와 조화를 이룰 것이다. 예수님의 이웃 사랑과 봉사의 정신을 실천하며, 정밀하고 신뢰할 수 있는 의료 서비스를 통해 환자들의 삶의 질을 높일 것이다. 이를 통해 AI 기술이 단순한 도구를 넘어 인간 중심의 윤리적 가치를 실현하는 데 기여할 것이다.

결론

본 프로젝트는 기술적, 사회적, 경제적, 문화적 측면에서 강력한 잠재력을 지닌 연구일 것이다. 상용화에 성공한다면 의료 분야의 혁신을 선도하며, 보다 나은 의료 서비스를 제공하는 데 기여할 것이다. 동시에 기독교적 가치와 조화를 이루며, 공정하고 투명한 의료 시스템 구축의 새로운 가능성을 열어줄 것이다.

B.3 Engineering Ethics

이해 당사자들

- 환자: AI 기반 진단을 통해 직접적인 의료 혜택을 받는 대상.
- 전문 의료인: AI 모델을 활용해 보다 효율적이고 정확한 진단을 수행하는 의료 전문가.
- AI 개발자: AI 기술을 연구하고 발전시키며, 의료진의 요구를 충족하는 시스템을 개발하는 기술 전문가.
- 일반 대중: AI 기술을 통해 의료 서비스의 신뢰성을 경험하고, 그 발전 가능성을 체감하는 사회 구성원.

예상되는 문제점, 오용 및 악용 사례

- 오진: AI의 정확도가 100%에 이르지 못하기 때문에 진단 오류가 발생할 가능성이 존

재함.

- 보안 문제: 시스템의 취약점을 악용하여 데이터를 탈취하거나 손상시키는 공격이 발생할 가능성이 있음.
- 신뢰성 문제: 환자가 AI 기반 진단 결과를 신뢰하지 못하거나, 의료진과의 협력 과정에서 갈등이 발생할 가능성이 있음.
- 시스템 결함: 예측하지 못한 오류나 결함으로 인해 시스템이 제대로 작동하지 않을 가능성이 있음.

부작용, 오용 및 악용 사례를 예방하거나 완화하기 위한 대책

- 모델 성능 향상: 다양한 데이터를 수집하여 AI 모델을 지속적으로 학습시키고, 최신 기술을 도입해 정확도를 높일 것.
- 보안 강화: 데이터 암호화, 접근 제어, 최신 보안 패치 적용 등을 통해 시스템의 보안을 유지할 것.
- 시스템 안정성 개선: 다양한 예외 처리 및 오류 복구 기능을 도입하고, 다양한 상황을 고려한 테스트를 통해 안정성을 강화할 것.
- 규제 및 표준 준수: 의료 데이터 처리와 관련된 법률과 국제 표준을 철저히 준수할 것.
- 독립적 감독: AI 시스템의 성능과 안정성을 지속적으로 모니터링할 수 있는 독립적인 감시 기구를 도입할 것.
- 데이터 프라이버시 보호: 개인정보 보호법을 준수하며, 데이터 사용에 대한 투명성을 보장하고 환자의 동의를 철저히 받을 것.
- 교육 및 홍보: 의료진과 환자 모두에게 AI 기술의 장점과 한계를 명확히 알리고, 이를 통해 신뢰를 구축할 것.
- 임상 결과 공개: AI 진단 시스템의 신뢰성을 입증하기 위해 연구 및 임상 시험 결과를 투명하게 공개할 것.
- 피드백 시스템: 사용자와 의료진의 의견을 수집하여 지속적으로 시스템을 개선할 것.
- 윤리적 책임 준수: 개발 과정에서 높은 윤리적 기준을 유지하고, 기술의 한계와 가능성을 명확히 인식할 것.
- 지속적 학습과 개선: 최신 기술 동향을 학습하고, 이를 모델 개선에 반영할 것.
- 사용자 지원 강화: 사용자에게 친절하고 명확한 지원을 제공하여 시스템 사용 중 발생하는 문제를 신속히 해결할 것.

이해 당사자들

- 환자: 진단과 치료를 받는 직접적인 수혜자가 될 것이다.
- 의사 및 의료진: AI 모델을 활용하여 보다 정밀한 진단과 치료 계획을 수립하는 주체가 될 것이다.
- 병원 및 의료기관: AI 기반 진단 시스템을 도입하고 운영하며 의료 혁신을 이끄는 중심 기관이 될 것이다.
- 연구자 및 개발자: AI 모델과 알고리즘을 개발하고 개선하며 의료 기술의 발전을 주

도할 것이다.

- 일반 대중 및 사회: AI 진단 기술의 사회적 수용성과 신뢰도를 평가하며, 기술의 발전에 영향을 미칠 것이다.

예상되는 문제점, 오용 및 악용 사례

- 진단 오류: AI 시스템이 잘못된 진단을 내릴 가능성이 존재하며, 오진의 위험이 발생할 것이다.
- 데이터 프라이버시: 환자의 민감한 의료 데이터가 유출되거나 악용될 위험이 있을 것이다.
- 의존성 문제: 의료진이 AI 시스템에 과도하게 의존할 경우, 의료 판단 능력이 저하될 것이다.
- 윤리적 문제: AI의 결정 과정이 불투명할 경우, 환자와 의료진 간 신뢰 문제가 생길 것이다.
- 악의적 사용: 기술이 악용되어 의료 데이터가 조작되거나 오용될 가능성이 있을 것이다.
- 기술적 오류: 시스템 장애나 버그로 인해 진단 과정에서 문제가 발생할 것이다.

부작용, 오용 및 악용 사례를 예방하거나 완화하기 위한 대책

- 정기적인 검증 및 업데이트: AI 모델을 지속적으로 검증하고 최신 의료 지식을 반영하는 업데이트를 진행할 것이다.
- 데이터 암호화: 환자의 의료 데이터를 강력한 암호화 기법으로 보호하여 프라이버시 침해를 방지할 것이다.
- 이중 진단 체계: AI 진단 결과를 의료진이 추가로 검토하는 이중 진단 체계를 도입하여 정확성을 확보할 것이다.
- 접근 권한 관리: 시스템 접근 권한을 철저히 관리하여 무단 접근 및 데이터 유출을 예방할 것이다.
- 사용자 교육: 의료진에게 AI 시스템의 원리와 한계를 교육하여 올바른 활용을 촉진할 것이다.
- 규제 및 인증: AI 진단 시스템에 대한 규제와 인증 제도를 마련하여 안전성과 신뢰성을 강화할 것이다.
- 표준화: 데이터 수집과 처리 과정에서 일관성을 유지하기 위해 표준화를 도입할 것이다.
- 책임 소재 규명: 진단 오류 발생 시 책임 소재를 명확히 하는 제도를 마련할 것이다.
- 윤리 교육: AI 개발자와 의료진에게 윤리 교육을 제공하여 책임감을 고취시킬 것이다.
- 사회적 논의: AI 진단 기술의 사회적 영향을 공개적으로 논의하여 투명성을 확보할 것이다.
- 접근성 지원: 기술 도입이 어려운 의료기관에 지원을 제공하여 기술 접근성을 높일 것이다.
- 투명한 개발 과정: AI 시스템의 개발 과정을 공개하여 신뢰를 구축할 것이다.

- 지속적인 모니터링: 시스템 사용 이후에도 지속적으로 모니터링하며 개선 사항을 반영할 것이다.
- 사용자 피드백: 의료진과 환자들의 피드백을 적극적으로 수렴하여 시스템 성능을 개선할 것이다.
- 윤리적 설계: AI 시스템의 설계 단계부터 윤리적 요소를 반영하여 책임 있는 기술 개발을 실현할 것이다.

B.4 전문인으로서 자기주도적 평생학습 계획

현대 사회의 급변하는 기술 속에서 경쟁력을 유지하고 전문가로 성장하기 위해서는 단순히 교실에서 배운 지식에만 의존하지 않고, 지속적인 자기 계발과 평생 학습이 필수적이다. 이에 나는 재학 기간 동안 전공 수업 외에도 최신 기술 동향과 실제 문제 해결 능력을 함양하기 위해 다양한 방법으로 학습을 이어왔으며, 졸업 이후에도 이를 바탕으로 전문성을 더욱 높여 나갈 것이다.

재학 중 전공 과목에서 다루지 않는 최신 기술과 이론을 배우기 위해 다양한 활동을 적극적으로 수행했다. 첫째, 최신 기술 동향을 파악하기 위해 학술 논문과 기술 블로그를 읽었다. 예를 들어, 딥러닝의 Transformer 모델이나 분산 컴퓨팅 기술과 같은 학문적 트렌드에 대한 이해를 넓히기 위해 관련 내용을 분석하며 스스로 학습했다. 둘째, 슬기까지 전산동아리에 가입하여 Conv2D와 같은 논문을 읽어 보고 YOLOv5를 직접 학습시켜보았다. 이 경험을 통해 딥러닝 모델에 익숙해질 수 있었다. 또한, 연구실에서 진행된 프로젝트에 참여하며 실질적인 문제 해결 경험을 쌓았다. 특히 의료 데이터를 활용한 인공지능 모델 개발 프로젝트에서는 척추굴반지표(Spinopelvic Parameter)를 자동으로 분석하는 AI 모델을 설계하며, 이론 지식을 실제 데이터에 적용하고 문제를 해결하는 과정을 경험했다. 이를 통해 데이터를 처리하는 방법과 의료 영상 분석에서 발생하는 문제를 해결하는 기술적 역량을 키울 수 있었다.

졸업 이후, 단기 목표는 급변하는 전자공학/컴퓨터공학 분야에서 최신 기술 동향과 이론을 지속적으로 학습하며 실질적인 기술 역량을 강화하는 것이다. 이를 위해 다음과 같은 방법을 계획하고 있다. 빠르게 변화하는 기술 환경에 적응하기 위해 최신 논문을 정기적으로 읽고, 컨퍼런스나 세미나에 참석할 것이다. 예를 들어, AAAI, CVPR와 같은 주요 학술 대회에서 발표된 최신 연구를 분석하고, 이를 내 연구에 적용하는 방법을 학습할 계획이다. 졸업 후에도 AI 대학원에 입학하여 새로운 알고리즘과 기술을 익히겠다. 이를 통해 특정 기술에 대해 깊이 이해하고 실무 능력을 더욱 강화할 것이다. 뿐만 아니라, 개인적으로 흥미를 느끼는 주제를 중심으로 프로젝트를 진행하며 실제 데이터를 다루고 문제를 해결하는 연습을 이어가겠다. 이를 통해 기술을 실질적인 응용으로 연결할 수 있는 능력을 키울 것이다.

장기적으로는 전문성을 확장하고 업계에서 인정받는 AI 연구자로 성장하는 것을 목표로 하고 있다. 이를 위해 다음과 같은 계획을 세웠다. 졸업 후에도 다양한 기업 및 연구소와의 산학협력을 통해 산업 현장에서 발생하는 문제를 해결하는 연구를 지속할 것이다. 특히, 의료 영상 분석, 데이터 처리와 같은 분야에서 실제 문제 해결 능력을 키우고자 한다. 더불어 연구원이 되어 학문적

지식을 심화하고, 연구 결과를 학술지에 발표하며 전문성을 인정받는 연구자로 성장하고자 한다. 특히, 연구 성과가 단순히 학문적 성취에 그치지 않고 사회적 가치를 창출할 수 있도록 노력할 것이다. 특히, 의료 분야에서 인공지능 기술을 활용하여 사람들의 삶의 질을 향상시키고, 의료 접근성을 높이는 데 기여하는 응용 방안을 모색할 것이다.

컴퓨터 공학은 끝없는 배움의 연속이라고 생각한다. 현대 사회의 첨단 기술은 끊임없이 발전하고 있다. 특히나 내가 큰 관심을 갖고 있는 AI 분야는 그 속도가 더욱 빠르다고 생각한다. 재학 중 나는 전공 수업과 더불어 인공지능 관련 학습을 꾸준히 이어왔다. 전공 공부로는 모든 인공지능 관련 수업을 수강했으며, 3학년 때는 4학년 수업인 머신러닝을 미리 수강하고, 학교에서 진행한 SW 인공지능 육목 대회에도 참가한 경험이 있다. 이 대회를 통해 학교 수업에서는 접하지 못했던 인공지능 기술인 강화학습에 대해서도 자연스럽게 경험할 수 있었다. 팀원들과 매주 강화학습 기술 관련 자료를 조사하고 스터디를 진행하며 더욱 깊이 있는 학습도 할 수 있었다.

3학년부터 나는 인공지능 관련 기술을 스스로 찾아보고 경험하기 위해 노력했다. 블로그를 통해 기술 정보를 검색하고, 간단한 논문을 읽으며 지식을 조금씩 쌓아갔다. 또한, '시선' 학회에서 학회원들과 다양한 IT 주제에 대해 논의하고 프로젝트를 진행하면서 팀으로서의 협업 경험도 쌓을 수 있었다. 학회 선배들의 특강을 통해 전공 지식뿐 아니라 미래 IT 관련 취업 정보도 얻을 수 있었다.

4학년이 되어서는 인공지능 관련 논문을 더 많이 읽으며 학습의 깊이를 더했다. 캡스톤 프로젝트를 준비하며 필요했던 논문들뿐만 아니라 개인적으로 궁금했던 분야의 논문들도 탐독했다. 연구실에서는 캡스톤 프로젝트를 함께하는 팀원들과 스터디를 하며 인공지능 연구에 대해 토론하며 많은 것을 배울 수 있었다. 특히 의료 데이터를 활용한 인공지능 모델 개발 프로젝트에서 척추골반지표(Spinopelvic Parameter)를 자동으로 분석하는 AI 모델을 설계하며, 이론을 실제 데이터에 적용하고 문제를 해결하는 과정도 경험할 수 있었다. 이를 통해 실제 데이터 전처리 방법과 의료 영상 분석에서 발생하는 크고 작은 문제들을 해결하는 기술적 역량을 키울 수 있었다.

다양한 코딩 테스트와 대회에도 참가하면서, 미래 취업을 대비해 코딩 실력도 함께 향상시켜왔다. 컴퓨터 공학자로서 인공지능 관련 전문 지식만큼이나 코딩 능력도 중요하다고 생각했다. 4학년 2학기에는 학교의 대표로 ICPC 전국 코딩 대회에 참가하기도 했으며, 이러한 경험을 통해 코딩 테스트 실력을 꾸준히 연마해왔다. 코딩 능력과 AI 리터러시 역량을 갖춘 SW 개발자로 성장하기 위해 끊임없이 노력했다.

졸업 후에도 인공지능 기술 동향에 대해 지속적으로 학습할 계획이다. 논문을 읽고, 공개된 오픈 소스를 찾고 직접 실행해보며 경험을 쌓을 것이다. 또한, 블로그를 만들어 지금까지의 학습 내용을 모두 정리하고 공유할 계획이다. 컴퓨터 공학과 인공지능 기술의 빠른 발전 속도를 따라잡기 위해서는 꾸준한 탐구와 학습이 필수적이라고 생각한다. 나는 인공지능 기술을 사용하고 있는 기업에 취업해 다양한 인재들과 함께 인공지능 프로젝트에 참여하며 다양한 경험을 쌓고 싶다. 특히, 의료 영상 분석과 데이터 처리 분야에서 실제 문제 해결 능력을 키우고 싶다. 캡스톤 프로젝트에서의 경험을 바탕으로 이를 더욱 보강해 나갈 수 있으리라 믿는다. 이를 위해 컴퓨터 공학뿐 아니라 의료 기술에 대한 지속적인 학습도 병행할 것이다.

이처럼 인공지능 관련 경험과 배움을 토대로, 먼 미래에는 팀을 이끌고 프로젝트에서 빛을 발휘하는 리더형 개발자로 성장하고자 한다.

B.5 프로젝트 수행 개인별 소감

최종 졸업 작품인 캡스톤 프로젝트에서 인공지능 개발 과정을 경험하게 되었다. 시작은 쉽지 않았다. 척추골반지표(Spinopelvic Parameter)와 같은 생소한 주제를 다루는 것이 처음이었기에, 기본 개념조차 익히는 데 시간이 걸렸고, 초기에는 혼란스러움과 어려움이 많았다. 하지만 다 함께 같은 목표를 세우고 분석에 집중한 결과, 작은 성취감을 느낄 수 있었다. 특히 TransUNet을 활용해 척추뼈를 식별하고, 이를 바탕으로 척추골반지표를 계산하는 과정에서 처음에는 막막했지만, 하나의 모델을 완전히 이해하고 나니 이후 다른 모델들을 빠르게 습득하는 데 큰 도움이 되었다.

또한, 프로젝트를 진행하며 빠르게 변화하는 인공지능 분야의 속도를 실감할 수 있었다. 불과 몇 주 사이에도 새로운 모델과 기법이 쏟아져 나왔고, 이를 따라가는 것이 도전처럼 느껴졌다. 하지만 이러한 경험은 최신 기술 트렌드에 적응하는 능력을 키우고, 새로운 지식을 배우는 데 대한 두려움을 줄이는 계기가 되었다. 특히, VQGAN을 활용해 척추 보조기구(screw)를 제거하고 복원 이미지를 생성하는 과정은 기술적 도전뿐만 아니라 큰 흥미를 느끼게 해준 작업이었다.

초기 목표는 새로운 AI 모델을 직접 설계하고 개발하는 것이었다. 하지만 현실적으로는 모델 구조를 수정하거나 기존 기법을 응용하는 수준에서 마무리되었다. 이 과정에서 자신의 부족함을 절실히 느꼈고, 동시에 더 많이 배우고 성장하고 싶다는 열망도 커졌다. 프로젝트를 진행하면서 척추골반지표를 추출하는 과정의 정확도를 높이는 방법을 고민하고, 실제 임상 환경에서 활용할 수 있는 Hspine GUI를 설계한 점은 큰 성과로 느껴졌다. 특히, 이 과정에서 팀원들과의 협업과 교수님, 다양한 자료들의 도움을 통해 문제를 하나씩 해결해 나가는 경험은 잊을 수 없는 성장의 시간이었다.

결과적으로, 이번 캡스톤 프로젝트는 단순히 기술적 학습을 넘어, 나의 가능성을 확인하고 앞으로의 방향성을 명확히 할 수 있는 기회가 되었다. 더불어, 척추골반지표 자동화를 통해 의료 영상 분석의 효율성과 정확도를 높이는 연구를 수행하며 인공지능이 실질적으로 사회에 기여할 수 있는 방법을 깊이 고민하게 되었다. 앞으로도 이러한 경험을 바탕으로 더 많은 것을 배우고, 발전된 모습을 보여줄 수 있도록 끊임없이 노력할 것이다.

캡스톤 디자인 프로젝트는 개인적으로 매우 의미 있는 경험이었다. 이번에 진행한 "척추 매개 변수 분석 자동화" 프로젝트는 단순히 기술적인 접근을 넘어 의료 분야에 딥러닝을 접목시키는 도전적인 작업이었다.

이번 프로젝트를 통해 딥러닝의 flow를 깊이 있게 학습할 수 있었다. 데이터 라벨링에서부터 모델 아키텍처 설계와 수정, 측정 알고리즘 설계에 이르기까지 전반적인 프로세스를 경험하며, 딥러닝

모델을 다루는 데 자신감을 얻게 되었다. 특히, 다양한 모델과 논문들을 접하면서 새롭게 배우는 즐거움을 느꼈고, 아직 배워야 할 것들이 많다는 점을 실감했다. 이를 통해 연구에 대한 흥미가 더욱 커졌다.

또한, 이번 프로젝트는 단순히 기술적인 배움에 그치지 않고, 실질적인 소통의 중요성을 일깨워주었다. 의사 선생님들과 직접 소통하며 연구 방향성을 점검하고 피드백을 반영해 개선해 나가는 과정은 연구의 실효성을 높이는 데 매우 중요한 경험이었다. 이러한 실무적인 접근은 책이나 강의에서 얻을 수 없는 귀중한 배움이었다.

이번 경험은 단순히 한 번의 프로젝트로 끝나는 것이 아니라, 앞으로의 성장에 지속적으로 영향을 줄 중요한 출발점이 될 것이다. 프로젝트를 통해 얻은 배움과 깨달음은 앞으로 더 큰 성장을 위한 밑거름이 될 것이며, 남은 시간 동안 더욱 열정을 가지고 연구를 이어 나가고 싶다.